

Nome:

Número:

MESTRADO EM ENGENHARIA INFORMÁTICA – UNIVERSIDADE DO MINHO

Teste Modelo de Análise de Dados de Grandes Dimensões

XX de YYYY de 2025 – Duração: 1h30

Instruções: Preencha o nome e o número de aluno no topo desta folha. Adicionalmente, pinte completamente (■) as caixas correspondentes aos dígitos do número na grelha ao lado (dígito das unidades na caixa mais à direita). Proceda da mesma forma para assinalar as respostas que considera correctas.

Não use as áreas sombreadas!

Nos exemplos de código-fonte assuma que as chamadas ao sistema executam corretamente e sem erros (a não ser que a pergunta indique explicitamente o contrário)

0	0	0	0	0	0
1	1	1	1	1	1
2	2	2	2	2	2
3	3	3	3	3	3
4	4	4	4	4	4
5	5	5	5	5	5
6	6	6	6	6	6
7	7	7	7	7	7
8	8	8	8	8	8
9	9	9	9	9	9

Grupo I

10 Valores

Questão 1 O Apache Spark tornou-se uma ferramenta amplamente utilizada para o processamento distribuído de grandes volumes de dados. Em comparação com o Hadoop MapReduce, apresenta vantagens significativas em termos de desempenho. Qual das seguintes características justifica essa melhoria de desempenho?

- ☐ A O Spark exige hardware mais potente que o Hadoop, o que o torna mais rápido.
- ☐ B O Spark apresenta suporte apenas para Java, simplificando o ambiente de execução.
- ☐ C O Spark utiliza um modelo de computação em memória, o que reduz o tempo de acesso aos dados.
- ☐ D O Spark baseia-se exclusivamente em processamento baseado em disco, o que evita perdas em memória.

Questão 2 O Spark executa transformações em grandes conjuntos de dados distribuídos. No entanto, a forma como constrói o plano de execução para estas transformações é fundamental para a sua eficiência. Em que modelo se baseia o plano de execução de tarefas no Apache Spark?


- ☐ A O Spark baseia o seu plano de execução no modelo de PageRank.
- ☐ B O Spark utiliza um Directed Acyclic Graph (DAG), que representa a sequência e dependências das operações.
- ☐ C O plano de execução do Spark é baseado em Random Walks, permitindo uma navegação aleatória nos dados.
- ☐ D O Spark constrói o seu plano de execução com base em Hash Trees.

Questão 3 Enquanto as transformações definem o pipeline de processamento, a execução real do plano é adiada até que uma determinada operação ocorra. Quais operações desencadeiam a execução efetiva de um programa em Spark?

- ☐ A O uso de caching inicia automaticamente o processamento das transformações definidas.
- ☐ B As ações são as operações que forçam a execução do plano de transformações no Spark.
- ☐ C O reparticionamento dos dados é responsável por iniciar o plano de execução.
- ☐ D A execução começa assim que se invocam funções de carregamento de dados.

Questão 4 Durante o treino de modelos de Machine Learning, o padrão shuffling é frequentemente utilizado. Qual a principal razão para essa escolha?


- ☐ A O shuffling melhora a compressão dos dados ao agrupá-los por similaridade antes do treino.
- ☐ B O shuffling de dados procura evitar viés devido à ordem dos dados.
- ☐ C O padrão shuffling é utilizado para reduzir o número total de dados processados, tornando o treino mais leve.
- ☐ D O padrão de shuffling permite eliminar a necessidade de utilização de batches.



Questão 5 Num cenário de treino assíncrono de modelos distribuídos, qual pode ser uma consequência negativa?

- ☐ **A** Quando existe assincronismo entre os nós, os gradientes utilizados para atualizar o modelo podem estar desatualizados, levando a inconsistências.
- ☐ **B** No treino assíncrono, o tempo de convergência é sempre superior ao síncrono.
- ☐ **C** Num cenário assíncrono, não podemos implementar paralelismo de modelo.
- ☐ **D** Quando usamos GPUs com diferentes arquiteturas, a execução torna-se inevitavelmente síncrona.


RASCUNHO



10 Valores

0 .1 .2 .3 .4 .5 .6 .7 .8 .9 1

[illegible]



0 .1 .2 .3 .4 .5 .6 .7 .8 .9 1

This image shows a single sheet of white paper with horizontal blue ruling lines. The lines are evenly spaced and run across the width of the page. There are no margins or other markings on the paper.