

Bioinformatics
Module 3 – session 1

Unsupervised learning

Dimensionality reduction

Clustering

Summary



usado para data base

- ML definitions and paradigms
- Clustering: definitions, algorithms, examples
 - Hierarchical clustering
 - K-means clustering
- Dimensionality reduction: definitions, methods, examples
 - Principal component analysis
 - Manifold learning: Multidimensional scaling, tSNE, UMAP

- Definições e paradigmas de ML
- Clustering: definições, algoritmos, exemplos
 - Clustering hierárquico
 - Agrupamento K-means
- Redução de dimensionalidade: definições, métodos, exemplos
 - Análise de componentes principais
 - Aprendizado múltiplo: escalonamento multidimensional, tSNE, UMAP

Machine Learning

Definition:

A computer program learns from experience E , in a class of tasks T , given a performance measure P , if its performance on the tasks contained in T , measured by P , improves with experience E .

(Mitchell, 1997)

Um programa de computador aprende com a experiência E , numa classe de tarefas T , dada uma medida de desempenho P , se o seu desempenho nas tarefas contidas em T , medido por P , melhorar com a experiência E . (Mitchell, 1997)

quando temos um programa de computador que é capaz de melhorar a sua performance a partir da experiência do computador

um exemplo que usa machine learning é o chat gpt, o word, o excel, a siri, etc.

ex: doentes com cancro -->
verificar qual o melhor
tratamento para cada
paciente

analise com feedback nao
direto mas geral (ex: fazer
um teste e saber a nota
(nao se sabe o que se
errou mas sabe se se no
geral foi bom ou mau)

Machine Learning Paradigms

Unsupervised

no external indication is provided, and learning is accomplished by discovering regularities/ patterns in the input data (e.g. clustering, dimensionality reduction).

nenhuma indicação externa é fornecida e o aprendizado é realizado pela descoberta de regularidades/padrões nos dados de entrada (por exemplo, agrupamento, redução de dimensionalidade).

Supervised

a correct answer is provided for each situation; learning is performed from examples composed of an input (typically a vector of values for a set of features) and a desired output.

é fornecida uma resposta correta para cada situação; o aprendizado é realizado a partir de exemplos compostos por uma entrada (normalmente um vetor de valores para um conjunto de características) e uma saída desejada.

Semi-supervised

an hybrid of the previous two cases, where only part (typically a smaller part) of the examples have known labels and other data is unlabelled

um híbrido dos dois casos anteriores, onde apenas parte (normalmente uma parte menor) dos exemplos tem rótulos conhecidos e outros dados não são rotulados

Unsupervised learning

We will cover here two main classes of unsupervised learning, providing examples of biological applications in both cases:

- **Clustering**, where the purpose is to group data given some defined criteria/ objectives
- **Dimensionality reduction**, where the purpose is to find variables (latent) that can be used to reduce the dimension of the data, in many cases towards improved visualization

Abordaremos aqui duas classes principais de aprendizagem não supervisionada, fornecendo exemplos de aplicações biológicas em ambos os casos:

- Clustering, onde o objetivo é agrupar dados de acordo com alguns critérios/objetivos definidos
- Redução da dimensionalidade, onde o objetivo é encontrar variáveis (latentes) que possam ser utilizadas para reduzir a dimensão dos dados, em muitos casos para melhorar a visualização

Genome-scale data: omics data + metadata

Em métodos não supervisionados, apenas esses dados são usados para executar os algoritmos!

In **unsupervised methods**, only these **data** are used to run the algorithms !

Data

thousands/
tens of
thousands

← tens / hundreds → (input)

	Sample 1	Sample 2	Sample 3	...
Gene 1	4.5	12.1	9.7	...
Gene 2	12.4	7.8	7.3	..
Gene 3	9.4	6.5	8.9	...
Gene 4	13.1	15.1	12.7	...
Gene 5	8.5	11.3	14.1	...
...	...	...	...	...

numerical

Nos métodos não supervisionados, os Metadata são utilizados apenas na análise dos resultados dos métodos

Metadata

In **unsupervised methods**, **metadata** is only used in the **analysis** of the results of the methods

	Blood test	Mutation	Smoker	Cancer sub-type
Sample 1	234.1	Negative	Y	A
Sample 2	117.2	Type I	N	B
Sample 3	90.7	Type II	N	A
...	...	...	...	...

a análise não supervisionada pega nestes dados e faz uma coisa com eles (metadados são os dados q não se usam para análise mas sim para interpretar resultados).

(qual a melhor forma de agrupar, como meço esse agrupamento. O que é similar e o que é diferente)

Objetivo (genérico): agrupar objetos/entidades/exemplos com base em sua similaridade para encontrar grupos naturais em dados

- que estão distantes um do outro
- em que “objetos” estão próximos uns dos outros

Clustering - definitions

Objective (generic): **grouping objects/ entities / examples** based on their similarity to find natural groups in data

- which themselves are far apart
- in which “objects” are close together

Clustering is not a well defined mathematical/ computational problem, but rather a set of **optimization** problems with several variants/ formulations depending on:

- Types of available **data** (e.g. numeric vs nominal attributes)
- Format of the desired **results**
- **Objective function** to optimize the partition
- **Similarity function** among the examples

Clustering não é um problema matemático/computacional bem definido, mas sim um conjunto de problemas de otimização com diversas variantes/formulações dependendo de:

- Tipos de dados disponíveis (por exemplo, atributos numéricos versus nominais)
- Formato dos resultados desejados
- Função objetiva para otimizar a partição
- Função de similaridade entre os exemplos

Clustering - definitions

- Different **inputs** (e.g. numerical vs categorical data)
- Different ways to measure **similarity/ distance**:
 - Define what is “far apart” and “close together”: this measure should capture what we think is important for the grouping
 - the choice for a certain distance measure is often the most important choice in clustering!
- Different **objective functions** (e.g. homogeneity vs separation)
- Distinct outputs/ desired **results**: “rigid”/crisp clusters (1 object belongs to one cluster), probabilities (fuzzy clustering), hierarchies

- Entradas diferentes (por exemplo, dados numéricos versus dados categóricos)
- Diferentes maneiras de medir similaridade/distância:

-Definir o que está “distante” e “próximo”: esta medida deve capturar o que consideramos importante para o agrupamento
-a escolha de uma determinada medida de distância é muitas vezes a escolha mais importante no agrupamento!

- Diferentes funções objetivo (por exemplo, homogeneidade vs separação)
- Saídas/resultados desejados distintos: clusters “rígidos”/nítidos (1 objeto pertence a um cluster), probabilidades (clustering fuzzy), hierarquias

(exemplos de distancias que se usam em termos matematicos

nas posições onde temos valores mais altos, a correlação é alta - onde um sobe o outro sobe e onde um desce o outro desce)

Similarity (numeric features)

Sometimes difficult to determine what is similar or not!

Measuring **Distances**: Euclidean, Manhattan

Às vezes é difícil determinar o que é semelhante ou não! Medindo Distâncias: Euclidiana, Manhattan

Manhattan

$$d(i, j) = |x_{i_1} - x_{j_1}| + |x_{i_2} - x_{j_2}| + \dots + |x_{i_p} - x_{j_p}|$$

Euclidean

$$d(i, j) = \sqrt{(|x_{i_1} - x_{j_1}|^2 + |x_{i_2} - x_{j_2}|^2 + \dots + |x_{i_p} - x_{j_p}|^2)}$$

Measuring similarity of shapes: coefficients of **correlation** (parametric or nonparametric)

Medindo similaridade de formas: coeficientes de correlação (paramétricos ou não paramétricos)


Homogeneity and separation

Homogeneity - Elements within a cluster must be close to each other (low distances) – intra-cluster (agrupar coisas similares nos mesmos grupos)

Separation - Elements in different clusters should be quite separate from each other (high distances) – inter-cluster (agrupar grupos diferentes em grupos diferentes)

... given that these are the two goals of clustering this is not a simple task!!

Example




Homogeneidade - Os elementos dentro de um cluster devem estar próximos uns dos outros (distâncias baixas) – intra-cluster


Separação - Elementos em clusters diferentes devem estar bem separados uns dos outros (grandes distâncias) – inter-cluster

... dado que estes são os dois objetivos do clustering esta não é uma tarefa simples!!

Which solution would you choose for a good clustering (and why) ?



VS




esta é melhor, mas nao perfeita

Clustering: "bad" solution

Violates homogeneity and separation

Viola a homogeneidade e a separação




ha muitos casos que violam tanto a homogeneidade como a separação

Clustering: "good" solution

Solution with good homogeneity and separation

Solução com boa homogeneidade e separação



Still, some pairs of points would be better grouped together in the previous solution

Ainda assim, alguns pares de pontos seriam melhor agrupados na solução anterior

Hierarchical Clustering

(clustering hierarquico
no inicio esta cada um no seu cluster e depois cria se uma especie de
arvore onde se criam os clusters semelhantes)

Agglomerative approach: it groups the objects, iteration by iteration, creating a tree that represents a hierarchy of clusters

Bottom up strategy, building the tree from the leaves to the root

Leafs of the tree: examples/ objects

Tree knots (branches): represent possible clusters

Join criterion based on the distance between clusters, i.e. we merge the two closest clusters in each iteration

Based on a **distance matrix**: where the distances between all pairs of objects are stored; this matrix is constructed by applying a similarity metric (e.g. Euclidean, Manhattan, correlation)

Abordagem aglomerativa: agrupa os objetos, iteração por iteração, criando uma árvore que representa uma hierarquia de clusters

Estratégia bottom up, construindo a árvore das folhas até a raiz

Folhas da árvore: exemplos/objetos

Nós de árvores (galhos): representam possíveis aglomerados

Critério de junção baseado na distância entre clusters, ou seja, mesclamos os dois clusters mais próximos em cada iteração

Baseado em uma matriz de distância: onde são armazenadas as distâncias entre todos os pares de objetos; esta matriz é construída aplicando uma métrica de similaridade (por exemplo, euclidiana, Manhattan, correlação)

Hierarchical Clustering: Distances between clusters

- **single linkage/nearest neighbour:** distance between 2 clusters is the shortest distance between pairs of elements of the two clusters.

$$d(C, C^*) = \min d(x, y) \text{ for all } x \text{ in } C^* \text{ and } y \text{ in } C$$

- **complete linkage:** distance between 2 clusters is the largest distance between pairs of elements of the two clusters.

$$d(C, C^*) = \max d(x, y) \text{ for all } x \text{ in } C^* \text{ and } y \text{ in } C$$

- **average linkage:** distance between 2 clusters is the average distance between pairs of elements of the two clusters.


$$d(C, C^*) = (1 / (|C^*| |C|)) \sum d(x, y) \text{ for all } x \text{ in } C^* \text{ and } y \text{ in } C$$

ligação única/vizinho mais próximo: a distância entre 2 clusters é a distância mais curta entre pares de elementos dos dois clusters.


ligação completa: a distância entre 2 clusters é a maior distância entre pares de elementos dos dois clusters.

ligação média: a distância entre 2 clusters é a distância média entre pares de elementos dos dois clusters.


Hierarchical Clustering: Distances between clusters



**Single
linkage**






**Complete
linkage**



**Average
linkage**

Hierarchical Clustering: summary



Iris dataset

(150 flores de 3 espétros diferentes. vão ser estudadas as pétalas por exemplo)

Iris
dataset

Dataset containing four numerical and one discrete variable. Numerical vectors represent the length and width of the petals and sepals from 150 flowers of three species: *setosa*, *virginica* and *versicolor* (given on the last field, a vector with possible 3 levels)


- Given its simplicity, this dataset will be used in some of the sections to show examples that can illustrate how to run the different analyses (practical sessions) and explore their results.
- Here, we will consider the four features with petal and sepal measures as **data**, and the last field (species) as **metadata**

Conjunto de dados contendo quatro variáveis numéricas e uma discreta. Vetores numéricos representam o comprimento e a largura das pétalas e sépalas de 150 flores de três espécies: setosa, virginica e versicolor (dado no último campo, um vetor com 3 níveis possíveis)

• Dada a sua simplicidade, este conjunto de dados será utilizado em algumas secções para mostrar exemplos que possam ilustrar como executar as diferentes análises (sessões práticas) e explorar os seus resultados.

• Aqui, consideraremos as quatro feições com medidas de pétalas e sépalas como dados, e o último campo (espécie) como metadados

Example – iris dataset



o que esta a vermelho é uma especie e esta dividido. Nao se usa isto no clustering. esta separação nao foi dita ao algoritmo, o algoritmo é que a fez naturalmente. neste caso, a separação do algoritmo nao corresponde muito a separação correta

Results from applying **hierarchical clustering** to the iris dataset

Similarity metric: **Euclidean distance**, from standardized data

Distances between clusters calculated using **single linkage**

Leafes of the tree are coloured by the metadata (species), not used to run the algorithm


Resultados da aplicação de cluster hierárquico ao conjunto de dados da íris

Métrica de similaridade: distância euclidiana, a partir de dados padronizados

Distâncias entre clusters calculadas usando ligação única

As folhas da árvore são coloridas pelos metadados (espécies), não usados para executar o algoritmo

Example – iris dataset



Results from applying **hierarchical clustering** to the iris dataset
Same configuration as before, but now using **average linkage**


Resultados da aplicação de clustering hierárquico ao conjunto de dados iris
Mesma configuração de antes, mas agora usando ligação média

K-Means Clustering

- Groups the data by trying to divide the samples into k groups, minimizing the distances between points and centroids of the clusters.
- The k parameter is given by the user
- Definition:
 - Divides the set of N samples into k clusters- C, each being described by the mean μ_j of the samples of the cluster.
 - The means μ_j are usually called centroids
 - **Objective function:** find centroids that minimize the distance between the samples and the centroids:

$$\sum_{i=0}^n \min_{\mu_j \in C} (\|x_i - \mu_j\|^2)$$

This objective function measures homogeneity, separation or both ?



(quer se saber a distancia ao centro do cluster (centroide, que e a media de todas as coordenadas dos pontos de cada grupo))

Esta função objetivo mede homogeneidade, separação ou ambas?

Agrupa os dados tentando dividir as amostras em k grupos, minimizando as distâncias entre pontos e centróides dos clusters.

- O parâmetro k é fornecido pelo usuário

- Definição:

- Divide o conjunto de N amostras em k clusters-C, sendo cada um descrito pela média μ_j das amostras do cluster.

- Os meios μ_j são geralmente chamados de centróides

- Função objetivo: encontrar centróides que minimizem a distância entre as amostras e os centróides:

K-means clustering

This objective function favours homogeneous clusters, i.e. clusters concentrating points near the centroid

Although the optimal solution for this problem is **NP-hard** (i.e. there are no efficient algorithms), practical useful solutions can be obtained with simple heuristic algorithms such as the Lloyd algorithm, typically repeated for a large number of times

Esta função objetivo favorece aglomerados homogêneos, ou seja, aglomerados que concentram pontos próximos ao centróide

Embora a solução ótima para este problema seja NP-difícil (ou seja, não existem algoritmos eficientes), soluções práticas e úteis podem ser obtidas com algoritmos heurísticos simples, como o algoritmo de Lloyd, normalmente repetido por um grande número de vezes.

(este algoritmo faz:
define se os centros dos clusters a sorte
depois move se os pontos para esse centro e calcula se de novo o centro
isto faz com que depois o centro se mova e quando ja nao ha grande distancia)
(sabe se que e melhor de acordo com a metrica)

K-Means: Lloyd's algorithm

Generate randomly k clusters' centers

While cluster centers change

Assign each point a cluster C_i corresponding to the cluster with the nearest center

After assigning a cluster to each of the n points, calculate new centroids to the k clusters given by cluster center of gravity

Em implementações práticas, um número máximo de iterações é comumente definido para evitar loops muito longos

In practical implementations, a maximum number of iterations is commonly defined to avoid very long loops

Gere aleatoriamente k centros de clusters enquanto os centros dos clusters mudam

<https://www.youtube.com/watch?v=4b5d3muPQmA>

Atribui a cada ponto um cluster C_i correspondente ao cluster com o centro mais próximo

Depois de atribuir um cluster a cada um dos n pontos, calcule novos centróides para os k clusters dados pelo centro de gravidade do cluster

Features of K-means (Lloyd algorithm)

Efficient heuristic method but **does not guarantee optimal solutions**

Quality of the final solution is **dependent on the initial solution** randomly generated – Local optimization

Repeating the algorithm with several distinct starting solutions improves its efficiency and this is normally done in used implementations (the best solution – the one with best objective function value - is kept as the result)

Initial solution can be improved by creating a distribution of centroids that distributes them better (i.e. when each centroid is created, the probability of closer points is reduced)


Método heurístico eficiente, mas não garante soluções ótimas

A qualidade da solução final depende da solução inicial gerado aleatoriamente – Otimização local


Repetir o algoritmo com diversas soluções iniciais distintas melhora sua eficiência e isso normalmente é feito nas implementações utilizadas (a melhor solução – aquela com melhor valor da função objetivo – é mantida como resultado).

A solução inicial pode ser melhorada criando uma distribuição de centróides que os distribua melhor (ou seja, quando cada centróide é criado, a probabilidade de pontos mais próximos é reduzida)

Kmeans - example




Initialization: Random




Recalculating centroids

Kmeans - example



Step 2: Re-assign clusters



Recalculating centroids

Kmeans – example with iris dataset


Species	setosa	versicolor	virginica
clusters			
0	50	0	0
1	0	39	14
2	0	11	36

This analysis allows to compare results of the clustering with “natural” groups in data.

Note that these were not used in the clustering process !!

Esta análise permite comparar resultados do agrupamento com grupos “naturais” de dados.

Observe que eles não foram usados no processo de clusterização!!



This analysis allows check how groups from clustering “correlate” with original variables in the dataset

Esta análise permite verificar como os grupos do clustering “se correlacionam” com as variáveis originais no conjunto de dados


as especies so sao usadas na analise

(faz se $k=2$, $k=4$, etc ate atingir a função objetivo. quanto mais clusters se tem, menor a funcao objetivo. se se tiver 100 clusters, a funcao objetivo sera 0 aproximadamente.)

K-means – choosing k

- The selection of the K parameter is a user decision prior to running the algorithm, that heavily affects results, but is not trivial to make
- Different values of K may be tried, to allow comparison with distinct metadata and to study how the OF value behaves

Example with
the iris dataset



- A seleção do parâmetro K é uma decisão do usuário antes de executar o algoritmo, que afeta fortemente os resultados, mas não é trivial de fazer
- Diferentes valores de K podem ser tentados, para permitir a comparação com metadados distintos e para estudar como o valor OF se comporta

The **Elbow** method (heuristic) implies finding possible K values where the OF reduces significantly (from K-1), while moving to K+1 does not reduce a lot the OF
(notice the OF tends to reduce as the number of clusters increases)

O método Elbow (heurística) implica encontrar possíveis valores de K onde o OF reduz significativamente (de K-1), enquanto passar para K+1 não reduz muito o OF
(observe que o OF tende a diminuir à medida que o número de clusters aumenta)

- Existem diversos algoritmos alternativos para tarefas de agrupamento, que são adaptados aos diferentes requisitos relativos a dados de entrada, funções de similaridade, formato de saída desejado, funções objetivo e recursos computacionais disponíveis, entre outros fatores.

Other clustering algorithms

- There are many different **alternative algorithms** for clustering tasks, which are adapted to the different requirements regarding input data, similarity functions, desired output format, objective functions and available computational resources, among other factors.
- Some examples:
 - **Spectral clustering** - performs a low-dimension embedding of the affinity matrix between samples, followed by clustering, e.g., by Kmeans
 - **DBSCAN** and **OPTICS** – density-based - view clusters as areas of high density separated by areas of low density; clusters can be any shape
 - **Gaussian mixtures** - uses multiple Gaussian distributions to fit arbitrarily shaped data
 - **Affinity propagation** - creates clusters by sending messages between pairs of samples until convergence (based on a nearest-neighbour graph)

Alguns exemplos:

- Clustering espectral - realiza uma incorporação de baixa dimensão da matriz de afinidade entre amostras, seguido de agrupamento, por exemplo, por Kmeans
- DBSCAN e OPTICS – baseados em densidade – vêem os clusters como áreas de alta densidade separadas por áreas de baixa densidade; clusters podem ter qualquer formato
- Misturas gaussianas - usa múltiplas distribuições gaussianas para ajustar dados de formato arbitrário
- Propagação por afinidade - cria clusters enviando mensagens entre pares de amostras até a convergência (com base em um gráfico do vizinho mais próximo)

Dimensionality reduction

Objectives: given a large set of variables, discover a **smaller set of uncorrelated variables that explain most of the data variability**

In terms of data compression, we want a matrix with the lowest possible rank, that explains the data (and allow to rebuild them)

Most popular technique: **Principal component analysis (PCA)**

Objetivos: dado um grande conjunto de variáveis, descobrir um conjunto menor de variáveis não correlacionadas que expliquem a maior parte da variabilidade dos dados

Em termos de compressão de dados, queremos uma matriz com a classificação mais baixa possível, que explique os dados (e permita reconstruí-los)

Técnica mais popular: Análise de componentes principais (PCA)

Principal Component Analysis

It consists of an algebraic procedure that **converts the original variables** (typically correlated) into a set of **uncorrelated variables** (linearly) which are called **principal components (PC) or latent variables**

Analysis based on the covariance of the variables

PCs are ordered by the decreasing amount of variability (variance) they explain

Consiste em um procedimento algébrico que converte as variáveis originais (normalmente correlacionadas) em um conjunto de variáveis não correlacionadas (linearmente) que são chamadas de componentes principais (PC) ou variáveis latentes.

Análise baseada na covariância das variáveis

Os PCs são ordenados pela quantidade decrescente de variabilidade (variância) que eles explicam

Principal Component Analysis

Each PC is generated in such a way as to **explain maximum variability** of the part not yet explained, having to be **orthogonal** to previous PCs

Useful when there is a large number of data variables and these contain possible redundancy

PCA is sensitive to the scale of the data, so prior normalisation is recommended

Cada PC é gerado de forma a explicar a variabilidade máxima da parte ainda não explicada, devendo ser ortogonal aos PCs anteriores

Útil quando há um grande número de variáveis de dados e estas contêm possível redundância

O PCA é sensível à escala dos dados, portanto é recomendada a normalização prévia

Principal Component Analysis

PCA provides mapping of a space with N dimensions (N – number of original variables) for a space with M dimensions (where $M < N$)

The coordinates of the observations in the space of the new variables are called *scores (T)*

The new dimensions are linear combinations of the original variables, where the coefficients of these in the original space are called *loadings (P)*

The original data (X) are obtained by doing: $X = T.P^T$

If we consider only k principal components, we consider only the first k columns of the T and P matrices, reaching an approximations of the original data


PCA fornece mapeamento de um espaço com N dimensões (N – número de variáveis originais) para um espaço com M dimensões (onde $M < N$)
As coordenadas das observações no espaço das novas variáveis são chamadas pontuações (T)

As novas dimensões são combinações lineares das variáveis originais, onde os coeficientes destas no espaço original são chamados de carregamentos (P)


Os dados originais (X) são obtidos fazendo: $X = T.P^T$

Se considerarmos apenas k componentes principais, consideramos apenas as primeiras k colunas das matrizes T e P , chegando a uma aproximação dos dados originais

PCA – example with dataset iris



Graph showing the variance explained by each PC



(as cores não vem do PCA)

A setosa e mais diferente das outras)


Scores plot showing coordinates of the different flowers in the PC1/ PC2. Colours represent species, **which were not used in the PCA computations.**

Gráfico de pontuações mostrando as coordenadas das diferentes flores no PC1/PC2. As cores representam espécies que não foram utilizadas nos cálculos do PCA.

(o pca nao é orientado a visualização, é mais direcionado a relacionar as variancias)

(petal width e length verifica se que o tamanho e a largura estao mais relacionadas uma com a outra pois tem uma boa correlação)

PCA – example with dataset iris



Biplot showing coordinates of the different flowers in the PC1/ PC2 (dots coloured by species) + arrows (in red) showing the original variable in the new coordinates

Biplot mostrando as coordenadas das diferentes flores no PC1/PC2 (pontos coloridos por espécie) + setas (em vermelho) mostrando a variável original nas novas coordenadas

Multi-Dimensional Scaling - MDS (metodos mais orientados para visualizar)

Multi-Dimensional Scaling (MDS) is a technique of data visualization.

Given a matrix of distances between objects, the MDS algorithm attempts to place each of the objects in an n -dimensional space in order to preserve as best as possible their original distances.

Using $n = 2$ allows you to view the points in a 2D space; number of dimensions in an MDS chart can be ≥ 2 .

There are several variants of MDS including so-called metric and non-metric algorithms

Multi-Dimensional Scaling (MDS) é uma técnica de visualização de dados.


Dada uma matriz de distâncias entre objetos, o algoritmo MDS tenta colocar cada um dos objetos em um espaço n -dimensional para preservar da melhor forma possível suas distâncias originais.

Usar $n = 2$ permite visualizar os pontos em um espaço 2D; o número de dimensões em um gráfico MDS pode ser ≥ 2 .

Existem diversas variantes de MDS, incluindo os chamados algoritmos métricos e não métricos.

MDS – example with dataset iris

(o output é parecido ao do pca)



Plot showing coordinates of the different flowers in the calculated latent variables of the MDS.

Colours represent species, **which were not used in the MDS computations.**

Gráfico mostrando as coordenadas das diferentes flores nas variáveis latentes calculadas do MDS.
As cores representam espécies, que não foram utilizadas nos cálculos do MDS.

T-SNE

(indica o t de student)

T-SNE - ***t-Distributed Stochastic Neighbor Embedding*** - more recent alternative to PCA and MDS to perform dimensionality reduction and more focused on data visualization in 2D or 3D

Widely used for data visualization in Machine Learning and Deep Learning projects

It is a **non linear** technique, also known as **manifold learning**, and that like MDS is based on the preservation of distances in pairs of points, but using distinct objective functions

It is based on probability distributions over pairs of objects, where similar objects are assigned a higher probability.

The optimization process minimizes the divergence between two distributions in the original high-dimensional space and the generated low-dimensional one

T-SNE - t-Distributed Stochastic Neighbour Embedding - alternativa mais recente ao PCA e MDS para realizar redução de dimensionalidade e mais focada na visualização de dados em 2D ou 3D

Amplamente utilizado para visualização de dados em projetos de Machine Learning e Deep Learning


É uma técnica não linear, também conhecida como aprendizagem múltipla, e que assim como o MDS se baseia na preservação de distâncias em pares de pontos, mas utilizando funções objetivo distintas

Baseia-se em distribuições de probabilidade sobre pares de objetos, onde objetos semelhantes recebem uma probabilidade mais alta.

O processo de otimização minimiza a divergência entre duas distribuições no espaço original de alta dimensão e o espaço de baixa dimensão gerado

T-SNE – example with dataset iris

(acaba por ter um resultado similar porque o objetivo é o mesmo que é representar os dados)




(funciona melhor do q o MDS porque para varios dados representa melhor)

Plot showing coordinates of the different flowers in the calculated latent variables of the T-SNE.

Colours represent species, **which were not used in the computations.**

Gráfico mostrando as coordenadas das diferentes flores nas variáveis latentes calculadas do T-SNE.

As cores representam espécies, que não foram utilizadas nos cálculos.



Python libraries: “ecosystem” SciPy

(conjunto de recursos para computação científica que inclui muitas coisas como álgebra linear, processamento de sinal, interpolação, etc.)

SciPy is a set of open-source python libraries for various types of tasks in Mathematics, Science and Engineering – www.scipy.org

The SciPy library contains a set of basic resources for scientific computing, including among others functions for numerical integration/ ODEs, optimization, interpolation, signal processing, Fourier transforms, linear algebra, clustering, statistical analysis/testing, etc.

For reference: <http://docs.scipy.org/doc/scipy/reference/> where there is also a tutorial

A biblioteca SciPy contém um conjunto de recursos básicos para computação científica, incluindo entre outras funções para integração numérica/EDOs, otimização, interpolação, processamento de sinais, transformadas de Fourier, álgebra linear, agrupamento, análise/teste estatístico, etc.

Python libraries: pandas

Includes a set of functions and data structures to facilitate large-scale data analysis- <http://pandas.pydata.org>

This library is particularly useful for data pre-treatment and processing

Most important data structure for efficient data processing:
DataFrame

Tutorial: <http://pandas.pydata.org/pandas-docs/stable/tutorials.html>

Python libraries: statsmodels

Module that implements statistical models and statistical tests

It includes, but is not limited to: linear regression, statistical tests, nonparametric tests, analysis of variance, survival analysis, etc.

Examples and documentation in:

<http://statsmodels.sourceforge.net/stable/index.html>

Módulo que implementa modelos estatísticos e testes estatísticos

Inclui, mas não está limitado a: regressão linear, testes estatísticos, testes não paramétricos, análise de variância, análise de sobrevivência, etc.

Python libraries: matplotlib

Includes a set of features related to building graphics

URL: www.matplotlib.org

Implements various types of functions for data visualization in the form of graphs

It includes the pyplot interface that allows you to create graphs in a similar way to Matlab

Examples of chart types and their scripts:

<http://matplotlib.org/examples/index.html>

Beginner's guide: <http://matplotlib.org/users/beginner.html>

Implementa vários tipos de funções para visualização de dados na forma de gráficos
Inclui a interface pyplot que permite criar gráficos de forma semelhante ao Matlab

Python libraries: scikit-learn

Open-source library written in **Python** which allows the implementation of scripts for the application of Machine Learning methods in various problems

Efficient code; written using libraries *numpy*, *scipy*, *matplotlib*

Includes multiple models and algorithms for classification, regression, preprocessing, clustering, dimensionality reduction, model and attribute selection

Documentation in: <http://scikit-learn.org>

Biblioteca open-source escrita em Python que permite a implementação de scripts para aplicação de métodos de Machine Learning em diversos problemas

Código eficiente; escrito usando bibliotecas *numpy*, *scipy*, *matplotlib*

Inclui vários modelos e algoritmos para classificação, regressão, pré-processamento, agrupamento, redução de dimensionalidade, seleção de modelos e atributos

Hierarchical clustering in python

- Function **linkage** - package **scipy** (module **cluster**) allows to run the algorithm and define the similarity metric (**metric**) and the method used to calculate distances between clusters (**method**)
- Function **dendrogram** (same module) allows to represent the tree graphically using the **matplotlib** package
- Metadata can be represented (not used in the clustering process) as colors of the leaves
- There is also a class of the **scikit-learn** package that allows you to run hierarchical clustering (**AgglomerativeClustering**)

<https://scikit-learn.org/stable/modules/generated/sklearn.cluster.AgglomerativeClustering.html>

- Articulação de funções - pacote scipy (módulo cluster) permite executar o algoritmo e definir a métrica de similaridade (métrica) e o método usado para calcular distâncias entre clusters (método)
- Função dendrograma (mesmo módulo) permite representar a árvore graficamente usando o pacote matplotlib
- Os metadados podem ser representados (não usados no processo de agrupamento) como cores das folhas
- Há também uma classe do pacote scikit-learn que permite executar clustering hierárquico (AgglomerativeClustering)

K-means clustering in python

- K-means clustering can be run from the *scikit-learn* package, *cluster* module, using the class *Kmeans*
- The constructor allows to define several parameters including the number of clusters (k), the number of runs to try and the maximum number of iterations in each run
- The *fit* function applies the algorithm to a dataset, calculating the centroids of each cluster
- The function *predict* applies the assignment of clusters to data (the same or a different set) based on the calculated clusters
- Other clustering algorithms are available in the same module and follow a similar structure

<https://scikit-learn.org/stable/modules/generated/sklearn.cluster.KMeans.html>

<https://www.freecodecamp.org/news/8-clustering-algorithms-in-machine-learning-that-all-data-scientists-should-know/>

- O clustering K-means pode ser executado a partir do pacote scikit-learn, módulo cluster, usando a classe Kmeans
- O construtor permite definir vários parâmetros incluindo o número de clusters (k), o número de execuções para tentar e o número máximo de iterações em cada execução
- A função fit aplica o algoritmo a um conjunto de dados, calculando os centróides de cada cluster
- A função prever aplica a atribuição de clusters a dados (o mesmo conjunto ou um conjunto diferente) com base nos clusters calculados
- Outros algoritmos de clustering estão disponíveis no mesmo módulo e seguem uma estrutura semelhante

PCA in Python

- Class **PCA** (package **scikit-learn**- module **decomposition**) allows to configure and run the algorithm
- Constructor of the class allows to define number of PCs to calculate
- Function **fit** runs the algorithm over a data matrix
- Result: object contains the explained variance, loadings (**components_**), etc.
- Function **transform** calculates scores

More details:

<https://scikit-learn.org/stable/modules/generated/sklearn.decomposition.PCA.html>

- Classe PCA (pacote scikit-learn-module decomposition) permite configurar e executar o algoritmo
- Construtor da classe permite definir o número de PCs para calcular
- A função fit executa o algoritmo em uma matriz de dados
- Resultado: o objeto contém a variância explicada, cargas (**components_**), etc.
- Transformação de função calcula pontuações

MDS and tSNE em Python

(transform e predict são praticamente a mesma coisa dependendo do método)

- MDS and tSNE can be run from classes in the package **scikit-learn**, module **manifold**, that includes distinct manifold learning (non linear) dimension reduction methods
- Class **tSNE** - allows to configure and run the t-SNE algorithm
- Class **MDS** - allows to configure and run the MDS algorithm in both its metric and non.metric versions
- In both cases:
 - Function **fit** - runs the algorithms over a matrix of numeric data
 - Function **transform** - calculates the new coordinates of the points

More details:

<https://scikit-learn.org/stable/modules/manifold.html#>

- MDS e tSNE podem ser executados a partir de classes no pacote scikit-learn, module manifold, que inclui métodos distintos de redução de dimensão de aprendizagem múltipla (não linear)
- Classe tSNE - permite configurar e executar o algoritmo t-SNE
- Classe MDS - permite configurar e executar o algoritmo MDS tanto em suas versões métricas e não métricas
- Em ambos os casos:
 - Ajuste de função - executa os algoritmos em uma matriz de dados numéricos
 - Transformação de função - calcula as novas coordenadas dos pontos