

Bioinformatics
Module 3 – session 2

Introduction to Chemoinformatics

junção da química e da informática

Representações Moleculares


Pesquisa de subestrutura

Similaridade molecular

Introdução ao RDKit

Aprendizagem não supervisionada

Summary




- Representações compostas – 1D, 2D e 3D
- Pesquisa de subestrutura – Notação SMARTS
- Semelhança Molecular – Semelhança Tanimoto
- Bancos de dados moleculares e conjuntos de dados
- Introdução ao RDKit
- Aprendizagem não supervisionada para dados moleculares

Molecular Representations

1D

Line Notations

SMILES, InChI,
InChIkeys



2D

Graphs






Node and adjacency
matrices

3D

Molecular Conformations

3D coordinates and
connection tables



Line Notations (1D)



O primeiro bloco tem sempre 14 letras

Os smiles são os mais usados em bioinformática e são úteis em machine learning tanto visionado como não supervisionado

InChI = 1S / C6H12O6 / c7-1-2-3(8)4(9)5(10)6(11)12-2 / h2-11H,1H2 / t2-,3-,4+,5-,6- / m1 / s1



InChI=1S/C8H10N4O2/c1-10-4-9-6-5(10)7(13)12(3)8(14)11(6)2/h4H,1-3H3 (caffeine)

InChIKey=RYYVLZVUVIJVGH-UHFFFAOYSA-N

First block (14 letters)

Encodes molecular skeleton (connectivity)

Second block (8 letters)


Encodes stereochemistry and isotopes

character indicating the number of protons ('N' means neutral)


flag character for InChI version: 'A' for version 1

flag character ('S') indicates standard InChIKey (produced out of standard InChI)


Simplified Molecular-Input Line-Entry System (SMILES) Notation



SMILES string: ClCCCCO



SMILES string: C(CO)CCl




SMILES string: OCCCCl

Podem haver vários smiles
para a mesma molécula

From the molecule to the SMILES


1- numerar os
átomos das
moléculas ©

Propane



1 2 3
C C C

Propanol



1 2 3 4
C C C O

From the molecule to the SMILES - Rings

First guess →
1 2 3 4 5
C C O C C


Para representar um anel no SMILES, comece com o átomo no início do anel e feche-o especificando o átomo no final do anel. O fechamento do anel é indicado colocando o número dentro da notação SMILES e usando esse número para conectar os átomos no início e no final do anel.

C1---C1 # Ring

--COC-- # Items in the Ring

C1COCC1 # Put it together

Tetrahydrofuran (THF)



Como contar os aneis numa molécula? Temos de dizer ao smiles que existe um anel e não uma molécula
A presença do anel é indicada com a presença de um numero no inicio e no fim do anel

From the molecule to the SMILES - Rings

COCOCC # start by enumerating the atoms


C1----C1 # Ring

--OCOC-- # Items in the Ring

C1OCOCC1 # Put it together

= carbono – abrir anel- oxigênio – carbonoOxigenio – C-C-1

1,3-Dioxane




From the molecule to the SMILES - Branches

First guess $\longrightarrow$ 1 2 3 4 5
 C C C C C

Para representar estruturas ramificadas, são usados parênteses (). Os átomos dentro dos parênteses formam um ramo e os parênteses os agrupam. Para isopentano:

CC(C)CC



CC(C)CC adiciona se parênteses na parte com branches (Assume se o 2 como branch principal e 3 o sub branch)


From the molecule to the SMILES - Branches

CCCCCCC # start by enumerating the atoms

---(C)-(C)- # Branches

CCC(C)C(C)C # Put it together

2,3-Dimethylpentane




From the molecule to the SMILES – Double and Triple Bonds


O símbolo "=" é usado para representar uma ligação dupla entre dois átomos.

O símbolo "#" é usado para representar uma ligação tripla entre dois átomos.


Propane



Propene




Propyne



From the molecule to the SMILES – Aromatic Molecules

Aromatic atoms are typically represented using lowercase letters.

1,2-Difluorobenzene




Quando estão
num anel, os
átomos são
aromáticos

1 2 3 4 5 6 7 8
Fc1c(F)ccccc1

From the molecule to the SMILES – All Together with Tyrosine

NC(C(=O)O)Cc1ccc(O)cc1
or
NC(Cc1ccc(O)cc1)C(=O)O




Se se usar c pequeno não há
necessidade de por =, se se usar C
grande tem de se colocar

From the molecule to the SMILES – Geometric Stereoisomers – trans/cis conformations


A configuração em torno de ligações duplas é especificada pelos caracteres / e \. Por exemplo, os seguintes SMILES para E- e Z-1,2-difluoroeteno:

E-1,2-Difluoroethene



F/C=C/F

Z-1,2-Difluoroethene







F/C=C\F

From the molecule to the SMILES – Stereoisomerism – optical isomerism

"@" - sentido anti-horário (anticlockwise)

"@" - sentido horário (clockwise)

Esses símbolos são colocados no centro quiral






[C@@H](Br)(Cl)F

Molecular Graphs (2D) - Connection Tables

Uma tabela de conexão, no contexto da química e da representação molecular, é uma estrutura de dados que define a conectividade dos átomos em uma molécula.

Normalmente inclui informações sobre quais átomos estão ligados entre si e também pode conter detalhes adicionais, como tipos de ligação, tipos de átomos e coordenadas.

(Uma tabela para átomos e uma tabela para as ligações (ligação simples-1, ligação dupla-2, ligação tripla-3); o E e o Z são trans e cis)



SCT VIII

Atom table

Atom #	Atom type
1	C
2	C
3	C
4	C

Bond table

Atom 1	Atom 2	Bond order
1	2	1
2	3	2
3	4	1

SCT IX

Atom table

Atom #	Atom type
1	C
2	C
3	C
4	C

Bond table

Atom 1	Atom 2	Bond order
1	2	1
2	3	2
3	4	1

E

SCT X

Atom table

Atom #	Atom type
1	C
2	C
3	C
4	C

Bond table


Atom 1	Atom 2	Bond order
1	2	1
2	3	2
3	4	1

Z

Molecular Graphs (2D) - Adjacency Matrix


No contexto da química e da representação molecular, uma matriz de adjacência é uma matriz quadrada que representa a conectividade entre os átomos de uma molécula. Geralmente é combinado com matrizes com node and edge features.

Assim se a molécula não fosse dada dava para construir



Molecular Conformations (3D) - 3D Coordinates

No contexto da química e da representação molecular, uma matriz de adjacência é uma matriz quadrada que representa a conectividade entre os átomos de uma molécula. Geralmente é combinado com matrizes com recursos de nós e arestas.



Da para ter noção
de como a
molécula é
representada em
espaço 3D

Nesta
representação e
possivelter muito
mais informação
do que nas outras

Molecular Descriptors

Tipos de recursos:

0D: contagens de átomos, contagens de ligações ou pesos moleculares;


1D: impressões digitais e chaves de fragmentos;

2D: topologia molecular baseada na representação gráfica das moléculas;

3D: descritores geométricos;

4D: Nova dimensão para caracterizar as interações entre a molécula e o sítio ativo de um receptor ou os múltiplos estados conformacionais da molécula.

é possível ir dos descritores para uma molécula mas não o contrario. Tem se os smiles do composto e da para completar inúmeros valores, por tudo numa matriz de descritores Descritores são coisas que descrevem as moléculas



Molecular 0D Descriptors


Conta:

- Contagem de átomos
- Número de N, O, H, C, etc.
- Contagem de títulos
- Número de ligações simples, duplas e triplas
- Contagens de elétrons
- Contagem de doadores e aceptadores de hidrogênio

Propriedades moleculares

- Peso molecular
- LogP
- etc.

São muito simples; para contagem de átomos e ligações, solubilidade, toxicidade, peso molecular. São descritores que não tem em conta a molécula em si



Molecular 1D Descriptors

Fingerprints (Vetores binários)

- Circular
- Baseado em caminho
- Pares de átomos


Fragment key

- Chaves MACCS


Presença de grupos funcionais e estruturais

- por exemplo: carbamato de alquila, benzeno, fenol




Fragment key




Path-based fingerprint




Circular fingerprint



alkyl carbamate



benzene



phenol

Molecular 2D Descriptors

- Balaban's J index
- Topological polar surface area

$$J = \frac{q}{\mu + 1} \sum_{\text{edges } ij} (S_i S_j)^{-1/2}$$

q - number of edges in the molecular graph

$\mu = (q - n + 1)$ -
the cyclomatic number of the molecular graph


n – number of atoms in the molecular graph

S_i -
distance sums calculated over the rows and columns
of the topological distance matrix of the molecule, D.


não têm em
consideração
coordenadas 3D



Topological Polar Surface Area = 63.60




Topological Polar Surface Area = 119.05



Molecular 3D Descriptors

A única diferença para os descritores 2D é que consideram as coordenadas 3D, por isso dá para ver os ângulos, a estereoquímica, etc. O machine learning pode ser feito usando estes descritores

3D



Principais momentos de inércia


- Fator de forma inercial
- Excentricidade
- Asfericidade
- Índice de esferocidade

Raio de giração

CAPRICHIO

Morse

Molécula com peso molecular 100, grupo alquila e pKa x, com as conformações moleculares para saber qual a molécula



Substructure Search - SMARTS Notation

notações diferentes dos
smarts. São usadas para fazer
highlight de certa estrutura ou
grupo funcional de uma
molécula, por ex., para fazer
drug design e também química
analítica, para saber a
função/estrutura molecular

Encontrar um padrão específico (subgráfico) em uma molécula (gráfico).

É usado em praticamente todas as aplicações que empregam uma representação digital de uma molécula:

- Representação (para destacar um grupo funcional específico)
- Design de medicamentos (pesquisa em um banco de dados por estruturas e atividades semelhantes),
- Química analítica (procurar estruturas previamente caracterizadas e comparar seus dados com os de um desconhecido);


Normalmente, a pesquisa de subestrutura é realizada com uma linguagem de consulta chamada SMARTS

SMARTS – Atomic Primitives

esta notação tem uma língua própria que pode ter diferentes primitivas


[#6]

Significa que o número atômico é 6, que é o carbono




[H3]

Está-se à procura de um átomo com 3 hidrogénio ligados a si




[x3]

A procura de átomos com 3 ligações a outros átomos no anel




[R]

Todos os átomos pertencem a um anel




[D1]

Átomos com grau 1, ou seja, ligação explícita (em que não se contam hidrogénios (o H não conta))



[X3]

A procura de átomos com conectividade 3 (contam se hidrogénios também)




SMARTS Atomic Primitives


Symbol	Symbol name	Atomic property requirements	Default
*	wildcard	any atom	(no default)
a	aromatic	aromatic	(no default)
A	aliphatic	aliphatic	(no default)
D<n>	degree	<n> explicit connections	exactly one
H<n>	total-H-count	<n> attached hydrogens	exactly one ¹
h<n>	implicit-H-count	<n> implicit hydrogens	at least one
R<n>	ring membership	in <n> SSSR rings	any ring atom
r<n>	ring size	in smallest SSSR ring of size <n>	any ring atom ²
v<n>	valence	total bond order <n>	exactly one ²
X<n>	connectivity	<n> total connections	exactly one ²
x<n>	ring connectivity	<n> total ring connections	at least one ²
- <n>	negative charge	-<n> charge	-1 charge (-- is -2, etc)
+<n>	positive charge	+<n> formal charge	+1 charge (++ is +2, etc)
#n	atomic number	atomic number <n>	(no default) ²
@	chirality	anticlockwise	anticlockwise, default class ²
@@	chirality	clockwise	clockwise, default class ²
@<c><n>	chirality	chiral class <c> chirality <n>	(nodefault)
@<c><n>?	chiral or unspec	chirality <c><n> or unspecified	(no default)
<n>	atomic mass	explicit atomic mass	unspecified mass

SMARTS – Bond Primitives

_




.




=

esta notação tem uma língua própria que pode ter diferentes primitivas



[R]-[*]

esta notação tem uma língua própria que pode ter diferentes primitivas




SMARTS Bond Primitives


Symbol	Atomic property requirements
-	single bond (aliphatic)
/	directional bond "up" ¹
\	directional bond "down" ¹
/?	directional bond "up or unspecified"
\?	directional bond "down or unspecified"
=	double bond
#	triple bond
:	aromatic bond
~	any bond (wildcard)
@	any ring bond ¹

SMARTS – Logical Primitives

[!#6]




[!#6&!#8]




[#6]~[#8,X2]

o carbono com qualquer tipo de ligação ligado a um oxigênio com conectividade 2



[#6]~[#8,X2&H3]

um carbono ligado a um oxigênio com conectividade 2



SMARTS Logical Operators


Symbol	Expression	Meaning
exclamation	!e1	not e1
ampersand	e1&e2	a1 and e2 (high precedence)
comma	e1,e2	e1 or e2
semicolon	e1;e2	a1 and e2 (low precedence)

Os 2 de baixo são iguais porque no primeiro caso refere qualquer tipo de ligações



Substructure Search - using SMILES

- Se nenhum padrão precisar ser encontrado e apenas uma subestrutura for encontrada, a notação SMILES resolverá o problema.

C1c[nH]cn1



[CH2][OH1]



Molecular Similarity

- Semelhança entre duas ou mais moléculas em termos de suas propriedades estruturais, físico-químicas ou biológicas.


- Normalmente em quimioinformática é comum avaliar a similaridade com base na interseção de bits ativos nas impressões digitais:

- Tanimoto similarity:

$$T(A,B) = (A \cap B) / (A + B - A \cap B)$$

- Dice similarity:


$$DSC(A,B) = 2(A \cap B) / (A + B)$$



1	0	0	0	0	0	0	0
1	0	0	0	0	1	0	0



1	0	0	0	0	0	0	...
1	0	0	0	1	0	0	...

0.2758



Molecular Similarity

1. Calcule as semelhanças de todos os compostos (n) com um composto ou grupo específico de compostos (m).
2. A matriz final de semelhanças será de $n \times m$.
3. Aplicar um t-SNE ou qualquer outra técnica de aprendizagem não supervisionada;
4. Trace as duas primeiras dimensões.
5. O espaço químico latente de semelhanças pode ser visto no gráfico.




Unsupervised Learning for Molecular Data

Os dados químicos são frequentemente complexos, com milhões de estruturas disponíveis;

Técnicas de aprendizagem não supervisionadas:

- Clustering: Agrupamento de moléculas com base na similaridade;
- Redução de dimensionalidade: Reduzindo características moleculares complexas a dimensões inferiores.

Usado para descobrir padrões e relacionamentos ocultos e para manipular e visualizar conjuntos de dados grandes e de alta dimensão;



Databases and Datasets

- Databases:

- PubChem - 116M compounds;
- Chemical Entities of Biological Interest (ChEBI) - biological molecules and ontologies;
- ChemSpider - 128M compounds
- ChEMBL - assays data

- Datasets:

- MoleculeNet - <https://moleculenet.org/datasets-1>
- TDC commons - https://tdcommons.ai/single_pred_tasks/overview/
- ChEMBL assays - https://www.ebi.ac.uk/chembl/web_components/explore/assays/

Introduction to RDKit



Open-Source Cheminformatics
and Machine Learning

O RDKit é um kit de ferramentas de código aberto para quimioinformática e design de medicamentos auxiliado por computador. É uma coleção de ferramentas de quimioinformática e aprendizado de máquina que facilitam a análise e manipulação de estruturas químicas e dados relacionados.

Os principais recursos do RDKit incluem:

Manipulação de Estrutura Química: O RDKit fornece funcionalidades para trabalhar com estruturas químicas, incluindo análise e geração de representações moleculares, cálculo de descritores moleculares e manipulação de reações químicas.

Algoritmos de Quimioinformática: O kit de ferramentas inclui uma variedade de algoritmos para pesquisa de similaridade, pesquisa de subestrutura, impressão digital molecular e outras tarefas de quimioinformática.

Manipulação de Estrutura Molecular 3D: O RDKit suporta a manipulação e análise de estruturas moleculares tridimensionais, incluindo a geração de confórmeros.

Integração de banco de dados: O RDKit pode ser integrado a bancos de dados, possibilitando o armazenamento e recuperação de informações químicas.

Código aberto: o RDKit é distribuído sob a licença BSD, disponibilizando-o gratuitamente para uso acadêmico, industrial e comercial.

Introduction to RDKit + Unsupervised Learning in Python

- Jupyter notebooks
 - `rdkit_introduction.ipynb`
 - `unsupervised_molecules.ipynb`