

Laboratórios de Bioinformática

**Alinhamento de sequências: conceitos;
Blast**

Razões para comparar sequências

Existem **muitas** sequências para as quais a **estrutura/ função não são conhecidas**.

Existem **algumas** sequências para as quais a **estrutura/ função são conhecidas**.

Um bom alinhamento de duas sequências implica que estas são similares e que poderão ter uma **ascendência comum**.

Duas **sequências similares** têm uma probabilidade mais alta de terem **estruturas e funções semelhantes**.

O alinhamento de uma sequência com outra de função / estrutura conhecida pode trazer informações valiosas sobre a função / estrutura da primeira.

Alinhamento e similaridade

Alinhamento de sequências: procedimento de comparação de duas ou mais sequências, procurando séries de caracteres individuais que se encontrem na mesma ordem nas sequências.

Sequências são **similares** se número de caracteres idênticos (emparelhados durante o alinhamento) é elevado.

Não é possível comparar sequências biológicas sem realizar o seu alinhamento dada a existências de mutações de inserção / deleção

O que alinhar : Sequências biológicas

DNA / RNA

- Sequências de um alfabeto que contém os símbolos respeitantes às bases A, G, T (ou U), C e espaçosamentos (-).

-	C	A	G	T	G	C	A	T	G	-	A	C	A	T	A
T	C	A	G	-	G	C	-	T	C	T	A	C	A	G	A

Proteínas

- Alfabeto contém 20 letras representando os diferentes aminoácidos e pode conter espaçosamentos.

L	G	P	S	S	G	C	A	S	R	I	W	T	K	S	A
T	G	P	S	-	G	-	-	S	-	I	W	S	K	S	G

Tipos de alinhamento

Globais

- Tentam-se alinhar ambas as sequências na totalidade (assumindo tamanhos semelhantes)
- Podem identificar genes/ proteínas com estruturas globais e funções semelhantes

L	G	P	S	S	G	C	A	S	R	I	W	T	K	S	A
T	G	P	S	-	G	-	-	S	-	I	W	S	K	S	G

Locais

- Tentam-se alinhar segmentos das sequências.
- Podem identificar zonas conservadas ao longo da evolução que configurem, por ex., zonas funcionais ativas de proteínas.

L	G	P	S	S	G	C	A	S	R	I	W	T	K	S	A
T	W	N	R	-	G	C	A	S	R	I	W	M	R	D	W

Definição de alinhamento como problema de otimização

O **alinhamento de duas sequências** é o processo de procura pelo melhor emparelhamento de caracteres (letras) entre duas sequências, dada uma **função de mérito** que avalie cada possível alinhamento.

Trata-se, assim, de um **problema de otimização**, i.e., pretende-se descobrir a melhor solução de entre um universo de possíveis soluções.

Formulação do problema

Dadas:

- Duas **sequências** (e.g. proteínas, DNA)
- **Função objetivo** que permite avaliar cada possível alinhamento.

Retornar:

Emparelhamento ótimo entre as duas sequências, restando a ordem relativa dos elementos de cada sequência, podendo introduzir-se **espaçamentos** em cada uma delas, tal que a **função objetivo é a máxima possível**.

Funções objetivo

Tipicamente, a função objetivo adotada é **aditiva**, i.e. corresponde à soma dos termos associados a cada par de caracteres ou espaçamentos, sendo definida a partir de:

- **Matriz de substituição** para a co-ocorrência de caracteres;
- Função de **penalização** para a ocorrência de espaçamentos.

A escolha destes parâmetros influencia fortemente o resultado do alinhamento.

Matrizes de substituição (scoring matrices)

Tabelas que definem **pontuação** a adicionar à função de mérito, para cada **par de caracteres** (um de cada sequência).

São calculadas com base num modelo que considera as **probabilidades de substituição** de um aminoácido por um outro **em sequências relacionadas**

Probabilidades são estimadas por **frequências relativas** de substituição, calculadas a partir de **BDs biológicas**.

Valores correspondem ao **logaritmo** da divisão das probabilidades de substituição em sequências relacionadas, sobre a probabilidade de substituição em sequências não relacionadas (logaritmos tornam coerente a sua soma na função objetivo; valores são multiplicados por 10 e arredondados)

Matrizes de substituição: exemplo

Vamos assumir que temos 1000 pares de aminoácidos retirados de “bons” alinhamentos:

- Nos 1000, o par de aminoácidos SS aparece 32 vezes; se a probabilidade do aminoácido S for de 10%, deveríamos ter um valor esperado de $10\% \times 10\% \times 1000 = 10$ ocorrências deste par
- Score do par SS seria então de: $10 \times \log_{10}(32/10) = 5$
- No caso do par SL teríamos 9 casos; se a probabilidade de L é de 15%, o valor esperado do par seria de 15 ocorrências
- Score do par SL seria: $10 \times \log_{10}(9/15) = -2$
- Note que se os valores observados e esperados forem o mesmo, o score será de 0

Matrizes BLOSUM

Valores das probabilidades são baseados em AAs pertencentes a **regiões conservadas (blocks)** em famílias de proteínas (provenientes da BD Prosite).

Família de matrizes, em que a matriz BLOSUM i corresponde a matrizes calculadas para sequências com similaridades previstas de $i\%$.

Matriz BLOSUM62

	A	C	D	E	F	G	H	I	K	L	M	N	P	Q	R	S	T	V	W	Y
A	4																			
C	0	9																		
D	-2	-3	6																	
E	-1	-4	2	5																
F	-2	-2	-3	-3	6															
G	0	-3	-1	-2	-3	6														
H	-2	-3	1	0	-1	-2	8													
I	-1	-1	-3	-3	0	-4	-3	4												
K	-1	-3	-1	1	-3	-2	-1	-3	5											
L	-1	-1	-4	-3	0	-4	-3	2	-2	4										
M	-1	-1	-3	-2	0	-3	-2	1	-1	2	5									
N	-2	-3	1	0	-3	0	-1	-3	0	-3	-2	6								
P	-1	-3	-1	-1	-4	-2	-2	-3	-1	-3	-2	-1	7							
Q	-1	-3	0	2	-3	-2	0	-3	1	-2	0	0	-1	5						
R	-1	-3	-2	0	-3	-2	0	-3	2	-2	-1	0	-2	1	5					
S	1	-1	0	0	-2	0	-1	-2	0	-2	-1	1	-1	0	-1	4				
T	-1	-1	1	0	-2	1	0	-2	0	-2	-1	0	1	0	-1	1	4			
V	0	-1	-3	-2	-1	-3	-3	3	-2	1	1	-3	-2	-2	-3	-2	-2	4		
W	-3	-2	-4	-3	1	-2	-2	-3	-3	-2	-1	-4	-4	-2	-3	-3	-3	-3	11	
Y	-2	-2	-3	-2	3	-3	2	-1	-2	-1	-1	-2	-3	-1	-2	-2	-2	-1	2	7

Penalizações por espaçamentos

Modelo mais utilizado distingue entre o início de um espaçamento e a sua extensão (affine gap penalty):

$$P = g + r.x$$

- P – penalidade do espaçamento
- g – penalidade por início de um espaçamento
- r – penalidade pela extensão de um espaçamento por mais um carácter
- x – número de caracteres do espaçamento

Valores típicos: g entre -8 e -14; r entre -2 e -4.

Exemplo de avaliação de um alinhamento – *affine gap penalties*

L	G	P	S	–	G	C	A	S	G	I	W	T	K	S	A
Y	G	P	S	G	G	–	–	S	R	I	W	S	K	S	G

Matriz: BLOSUM62

Penalizações: $g = -12$; $r = -2$

Função de mérito do alinhamento:

$$-1 + 6 + 7 + 4 - 12 + 6 - 12 - 2 + 4 - 2 + 4 + 11 + 5 + 5 + 4 + 0 = 27$$

Algoritmos para alinhamento

Matrizes de pontos – análise e alinhamento visuais

Programação dinâmica – métodos exatos que garantem solução ótima:

- Needleman / Wunsch – alinhamentos globais
- Smith / Waterman – alinhamentos locais

Métodos heurísticos – mais rápidos; menos precisos

- FASTA
- BLAST

Procura por sequências similares em bases de dados - BLAST

Objetivo

Descrever e analisar algoritmos e ferramentas usadas para, dada uma sequência (query), **procurar sequências mais similares em bases de dados** (de sequências) de grande dimensão

Problema tem uma escala diferente do alinhamento de pares de sequências, pois as BDs têm tipicamente milhões de instâncias

Métodos heurísticos de alinhamento de sequências

Não garantem solução ótima.

São **mais rápidos** que os algoritmos de PD, na ordem das 50-100 vezes.

Se as sequências a comparar forem pouco similares, o ideal será utilizar a PD pois tem maior sensibilidade.

Ideais para **procuras em BDs**, onde se tem uma sequência e se procuram **sequências similares** em conjuntos de elevada cardinalidade.

Métodos mais conhecidos: **FASTA** e **BLAST**.

Critérios de avaliação

Na avaliação do desempenho destes algoritmos deveremos ter em conta:

- **Sensibilidade** = $VP / (FN + VP)$
% das sequências homólogas na BD que são retornadas
- **Precisão** = $VP / (VP + FP)$
% das sequências similares retornadas que são homólogas
- **Eficiência** computacional (tempo de resposta a um pedido)

VP – verdadeiros positivos (sequências homólogas efetivamente detetadas)

FP – falsos positivos (sequências detectadas que não são homólogas)

FN – falsos negativos (sequências homólogas não detetadas)

BLAST – Basic Local Alignment Search Tool

Algoritmo mais utilizado da atualidade na pesquisa em BDs de sequências.

Procura bons alinhamentos locais entre uma sequência query e sequências de uma base de dados definida

Usa pequenas “palavras” (e.g. 3 AAs ou 5-15 bases de DNA);

Procura palavras do mesmo tamanho nas sequências da BD, que comparadas com as palavras da sequência query tenham alta similaridade.

BLAST – Basic Local Alignment Search Tool

O match entre as “palavras” comuns formam a base de um alinhamento local que é posteriormente estendido nas duas direções

A extensão ocorre até o alinhamento baixar de um score pré-definido

BLAST: exemplo

$w = 4$


Caso DNA –match
exato: **GGTC**

Estender diagonais
com mismatches
(até 50%)


Resultado:

GTAAGGTCC

GTTAGGTCC



BLAST – exemplo com proteínas



Refinamentos do Blast

Numa versão mais recente (1997) passaram a exigir-se dois hits próximos independentes, separados por uma distância não superior a um parâmetro dado

Isto leva a menos extensões e logo a mais rapidez no algoritmo; resultados obtidos não pioram

Esta estratégia permite incluir gaps na zona estendida entre os dois hits

Outra melhoria: vários HSPs podem ser combinados para gerar alinhamentos maiores e de melhor qualidade; algoritmos de PD podem ser usados nesta tarefa

Programas BLAST

- **Nucleotide BLAST - blastn**

Procurar uma sequência de DNA na base de dados de DNA

- **Protein BLAST – blastp**

Procurar uma sequência de proteína na base de dados de proteínas

- **Blastx**

Procurar uma sequência de DNA traduzida na base de dados de proteínas

- **Tblastn**

Procurar uma sequência de proteína na base de dados de sequências de DNA traduzidas

- **Tblastx**

Procurar uma sequência de DNA traduzida na base de dados de sequências de DNA traduzidas

Programas BLAST

- Qualquer análise BLAST começa sempre com uma sequência (DNA, proteína)
 - Pode ter sido determinada experimentalmente
 - Pode ter sido obtida a partir de uma base de dados
 - NCBI (<https://www.ncbi.nlm.nih.gov/>)
 - UniProt (<https://www.uniprot.org/>)
 - ...

BLAST - Aspectos importantes a ter em consideração antes de efetuar uma análise

- Qualquer pedido de análise BLAST vai demorar algum tempo a ser processado
- Existem milhares de utilizadores diários do BLAST
- As bases de dados (DNA/Proteínas) contêm muita informação o que leva a um maior tempo de processamento



Tempo de processamento :



tamanho da sequência



especificidade da pesquisa



blastn

blastp

blastx

tblastn

tblastx

Standard Nucleotide BLAST

BLASTN programs search nucleotide databases using a nucleotide query. [more.](#)

Enter Query Sequence

Enter accession number(s), gi(s), or FASTA sequence(s) [?](#) [Clear](#)

Query subrange [?](#)

From

To

Or, upload file

Choose File

No file chosen

[?](#)

Job Title

Enter a descriptive title for your BLAST search [?](#)

☐ Align two or more sequences [?](#)

Choose Search Set

Database

☒ Standard databases (nr etc.): ☐ rRNA/ITS databases ☐ Genomic + transcript databases ☐ Betacoronavirus

Nucleotide collection (nr/nt) [?](#)

Organism

Optional

Enter organism name or id—completions will be suggested

☐ exclude [?](#)

Enter organism common name, binomial, or tax id. Only 20 top taxa will be shown [?](#)

Exclude

Optional

☐ Models (XM/XP) ☐ Uncultured/environmental sample sequences

Limit to

Optional

☐ Sequences from type material

Entrez Query

Optional

Enter an Entrez query to limit search [?](#)

[YouTube](#) [Create custom database](#)

Program Selection

Optimize for

☒ Highly similar sequences (megablast)

☐ More dissimilar sequences (discontiguous megablast)

☐ Somewhat similar sequences (blastn)



Choose a BLAST algorithm [?](#)

BLAST

Select database Nucleotide collection (nr/nt) using Megablast (Optimize for highly similar sequences)

☐ Show results in a new window

+ Algorithm parameters





Standard Protein BLAST

blastn
blastp
blastx
tblastn
tblastx

BLASTP programs search protein databases using a protein query, more...

Enter Query Sequence

Enter accession number(s), gi(s), or FASTA sequence(s) [?](#) [Clear](#)

Query subrange [?](#)

From

To

Or, upload file [?](#)

Choose File

No file chosen

Job Title

Enter a descriptive title for your BLAST search [?](#)

☐ Align two or more sequences [?](#)

Choose Search Set

Databases

☒ Standard databases (nr etc.): New ☐ Experimental databases

Compare ☐ Select to compare standard and experimental database [?](#)

Try experimental clustered nr database

For more info see [What is clustered nr?](#)

Standard

Database ?

Organism Optional ?

Enter organism common name, binomial, or tax id. Only 20 top taxa will be shown. [?](#)

Exclude Optional ☐ Models (XM/XP) ☐ Non-redundant RefSeq proteins (WP) ☐ Uncultured/environmental sample sequences

Program Selection

Algorithm

☐ Quick BLASTP (Accelerated protein-protein BLAST)

☒ blastp (protein-protein BLAST)

☐ PSI-BLAST (Position-Specific Iterated BLAST)

☐ PHI-BLAST (Pattern Hit Initiated BLAST)

☐ DELTA-BLAST (Domain Enhanced Lookup Time Accelerated BLAST)

Choose a BLAST algorithm [?](#)

BLAST

Search database nr using Blastp (protein-protein BLAST)

☐ Show results in a new window

+
Algorithm parameters

Bases de dados de DNA no BLAST



Choose Search Set

Database ☒ Standard databases (nr etc.): ☐ rRNA/ITS databases ☐ Genomic + transcript databases ☐ Betacoronavirus

Organism Optional

Exclude Optional

Limit to Optional

Entrez Query Optional

Program Selection

Optimize for

Nucleotide collection (nr/nt)

- RefSeq Select RNA sequences (refseq_select)
- Reference RNA sequences (refseq_ma)
- RefSeq Representative genomes (refseq_representative_genomes)
- RefSeq Genome Database (refseq_genomes)
- Whole-genome shotgun contigs (wgs)
- Expressed sequence tags (est)
- Sequence Read Archive (SRA)
- Transcriptome Shotgun Assembly (TSA)
- Targeted Loci(TLS)
- High throughput genomic sequences (HTGS)
- Patent sequences(pat)
- PDB nucleotide database (pdb)
- Human RefSeqGene sequences(RefSeq_Gene)
- Genomic survey sequences (gss)
- Sequence tagged sites (dbsts)

exclude [Add organism](#)

[YouTube](#) [Create custom database](#)

Title: Nucleotide collection (nt)

Description: The nucleotide collection consists of GenBank+EMBL+DDBJ+PDB+RefSeq sequences, but excludes EST, STS, GSS, WGS, TSA, patent sequences as well as phase 0, 1, and 2 HTGS sequences and sequences longer than 100Mb. The database is non-redundant. Identical sequences have been merged into one entry, while preserving the accession, GI, title and taxonomy information for each entry.

Molecule Type: mixed DNA

Update date: 2022/09/27

Number of sequences: 86382105

Bases de dados de Proteínas no BLAST

Choose Search Set

Databases ☒ Standard databases (nr etc.): **Now** ☐ Experimental databases [Try experimental clustered nr database](#)
For more info see [What is clustered nr?](#)

Compare ☐ Select to compare standard and experimental database ?

Standard


Database **Non-redundant protein sequences (nr)** ?
Organism ☐ exclude [Add organism](#)
Optional
Exclude ☐ taxa will be shown. ?
Optional (WP) ☐ Uncultured/environmental sample sequences

Program Selection

Algorithm ☐ Quick BLASTP (Accelerated protein-protein BLAST)
☒ **blastp (protein-protein BLAST)**
☐ PSI-BLAST (Position-Specific Iterated BLAST)
☐ PHI-BLAST (Pattern Hit Initiated BLAST)
☐ DELTA-BLAST (Domain Enhanced Lookup Time Accelerated BLAST)
Choose a BLAST algorithm ?

BLAST Search database nr using Blastp (protein-protein BLAST)
☐ Show results in a new window


Title: All non-redundant GenBank CDS translations+PDB+SwissProt+PIR+PRF excluding environmental samples from WGS projects
Molecule Type: Protein
Update date: 2022/09/27
Number of sequences: 507975733



Algoritmos otimizados de procura (DNA)

blastn

- Algoritmo tradicional do BLAST
- Permite uma pesquisa muito sensível (considera pequenas alterações)
- Mais lento



The image shows a screenshot of the 'Program Selection' section of a BLAST interface. It features a tab labeled 'Program Selection' and a section titled 'Optimize for'. There are three radio button options: 'Highly similar sequences (megablast)' which is selected, 'More dissimilar sequences (discontiguous megablast)', and 'Somewhat similar sequences (blastn)'. Below these options is a link that says 'Choose a BLAST algorithm' with a question mark icon.

megablast


- Atualmente é o algoritmo mais utilizado
- Mais rápido
- Adequado para sequências maiores
- Continuous megablast: otimizado para identificação de espécies
- Discontinuous megablast: otimizado para comparação entre espécies



Algoritmos otimizados de procura (Proteínas)

blastP / QuickBlastP

Algoritmos mais rápidos, menos sensíveis



PSI-BLAST/ PHI-BLAST / DELTA-BLAST

Algoritmos mais lentos, mais sensíveis



Exemplo de pesquisa de uma proteína e análise estatística no BLAST

BLAST® » blastp suite » results for RID-K85E09TG01R

Home Recent Results Saved Strategies Help

[< Edit Search](#) [Save Search](#) [Search Summary](#) [How to read this report?](#) [BLAST Help Videos](#) [Back to Traditional Results Page](#)

Job Title Protein Sequence

RID [K85E09TG01R](#) Search expires on 09-29 17:37 pm [Download All](#) [Citation](#)

Program BLASTP [See details](#)

Database nr [See details](#)

Query ID lcl|Query_306170

Description unnamed protein product

Molecule type amino acid

Query Length 222

Other reports [Distance tree of results](#) [Multiple alignment](#) [MSA viewer](#)

Filter Results

Organism only top 20 will appear ☐ exclude

Type common name, binomial, taxid or group name

[+ Add organism](#)

Percent Identity to **E value** to **Query Coverage** to

[Filter](#) [Reset](#)

Compare these results against the new Clustered nr database [BLAST](#)

Descriptions [Graphic Summary](#) [Alignments](#) [Taxonomy](#)

Sequences producing significant alignments [Download](#) [Select columns](#) [Show 100](#)

☒ select all 100 sequences selected [GenPept](#) [Graphics](#) [Distance tree of results](#) [Multiple alignment](#) [MSA Viewer](#)


	Description	Scientific Name	Max Score	Total Score	Query Cover	E value	Per. Ident	Acc. Len	Accession
☒	Chain A, Membrane protein [Severe acute respiratory syndrome coronavirus 2]	Severe acute respiratory syndrome coronavirus 2	452	452	100%	2e-160	100.00%	231	BCTK_A
☒	membrane glycoprotein [Severe acute respiratory syndrome coronavirus 2]	Severe acute respiratory syndrome coronavirus 2	452	452	100%	3e-160	100.00%	222	YP_009724393.1
☒	membrane glycoprotein [Severe acute respiratory syndrome coronavirus 2]	Severe acute respiratory syndrome coronavirus 2	452	452	100%	3e-160	99.55%	222	QOI80349.1
☒	membrane glycoprotein [Severe acute respiratory syndrome coronavirus 2]	Severe acute respiratory syndrome coronavirus 2	452	452	100%	3e-160	99.55%	222	QRX47137.1
☒	membrane glycoprotein [Severe acute respiratory syndrome coronavirus 2]	Severe acute respiratory syndrome coronavirus 2	452	452	100%	3e-160	99.55%	222	QRW77283.1
☒	membrane glycoprotein [Severe acute respiratory syndrome coronavirus 2]	Severe acute respiratory syndrome coronavirus 2	452	452	100%	3e-160	99.55%	222	QQF18748.1

Qual a significância estatística do alinhamento?

E-value: é um número que indica nº de alinhamentos com o mesmo score (ou maior) se todas as sequências na BD fossem aleatórias. Quanto menor, mais significativa é a correspondência

Max Score	Total Score	Query Cover	E value	Per. Ident	Acc. Len	Accession
452	452	100%	2e-160	100.00%	231	8CTK_A
452	452	100%	3e-160	100.00%	222	YP_009724393.1
452	452	100%	3e-160	99.55%	222	QOI60349.1
452	452	100%	3e-160	99.55%	222	QRX47137.1
452	452	100%	3e-160	99.55%	222	QRW77293.1
452	452	100%	3e-160	99.55%	222	QOF16748.1

Max Score: pontuação de alinhamento máxima calculada a partir da soma das recompensas relativas aos nucleótidos/ aminoácidos coincidentes e penalidades por *mismatches* e *gaps*



$$S = \sum(\text{identities, mismatches}) - \sum(\text{gap penalties})$$

$$\text{Score} = \text{Max}(S)$$

Total Score: soma das pontuações do alinhamento de todos os segmentos da mesma sequência. Esta pontuação é diferente do Max Score se várias partes das sequências da base de dados corresponderem a diferentes partes da sequência alvo.

Max Score ▼	Total Score ▼	Query Cover ▼	E value ▼	Per. Ident ▼	Acc. Len ▼	Accession
452	452	100%	2e-160	100.00%	231	8CTK_A
452	452	100%	3e-160	100.00%	222	YP_009724393.1
452	452	100%	3e-160	99.55%	222	QOI60349.1
452	452	100%	3e-160	99.55%	222	QRX47137.1
452	452	100%	3e-160	99.55%	222	QRW77293.1
452	452	100%	3e-160	99.55%	222	QOF16748.1

Percent identity: é um número que demonstra quão semelhantes são as duas sequências a ser comparadas (quantos resíduos em cada sequência são idênticos). Quanto maior, mais significativa é a correspondência.

Query cover: número que descreve quanto da sequência alvo é coberta pela sequência com que se está a comparar. Se a sequência da base de dados abranger toda a sequência alvo, a cobertura é 100%. Compara o tamanho das sequências.

Accession Length: tamanho da sequência

Descriptions

Graphic Summary

Alignments

Taxonomy

Alignment view

Pairwise

?

Restore defaults

Download

100 sequences selected

?

Download

GenPept

Graphics

Next

Previous

Descriptions

Chain A, Membrane protein [Severe acute respiratory syndrome coronavirus 2]

Sequence ID: [8CTK_A](#) Length: 231 Number of Matches: 1

See 1 more title(s) See all Identical Proteins(IPG)

Range 1: 1 to 222

GenPept

Graphics

Next Match

Previous Match

Score	Expect	Method	Identities	Positives	Gaps
452 bits(1164)	2e-160	Compositional matrix adjust.	222/222(100%)	222/222(100%)	0/222(0%)
Query 1	MADSNGTITVEELKKLLEQWNLVIGFLFLTWICLLQFAYANRNRFLYIIKLIFLWLLWPV				60
Sbjct 1	MADSNGTITVEELKKLLEQWNLVIGFLFLTWICLLQFAYANRNRFLYIIKLIFLWLLWPV				60
Query 61	TLACFVLAAYRINWITGGIAIAMACLVGLMWLSYFIASFRLFARTRSMWSFNPETNILL				120
Sbjct 61	TLACFVLAAYRINWITGGIAIAMACLVGLMWLSYFIASFRLFARTRSMWSFNPETNILL				120
Query 121	NVPLHGTILTRPILLESELVIGAVILRGHLRIAGHHLGRCDIKDLPKEITVATSRTLSTYYK				180
Sbjct 121	NVPLHGTILTRPILLESELVIGAVILRGHLRIAGHHLGRCDIKDLPKEITVATSRTLSTYYK				180
Query 181	LGASQRVAGDSGFAAYSRYRIGNYKLNTDHSSSSDNIALLVQ			222	
Sbjct 181	LGASQRVAGDSGFAAYSRYRIGNYKLNTDHSSSSDNIALLVQ			222	

Download

GenPept

Graphics

Next

Previous

Descriptions

membrane glycoprotein [Severe acute respiratory syndrome coronavirus 2]

Sequence ID: [YP_009724393.1](#) Length: 222 Number of Matches: 1

See 6 more title(s) See all Identical Proteins(IPG)

Related Information

Identical Proteins - Identical proteins to 8CTK_A

Chain A, Membrane protein [Severe acute respiratory syndrome coronavirus 2]

Sequence ID: [BCTK_A](#) Length: 231 Number of Matches: 1

[See 1 more title\(s\)](#) [See all Identical Proteins\(IPG\)](#)

Range 1: 1 to 222 [GenPept](#) [Graphics](#)

[Next Match](#) [Previous Match](#)

Score	Expect	Method	Identities	Positives	Gaps
452 bits(1164)	2e-160	Compositional matrix adjust.	222/222(100%)	222/222(100%)	0/222(0%)
Query 1	MADSNGTITVEELKKLLEQWNLVIGFLFLTWICLLQFAYANRNRFLYIIKLIFLWLLWPV				60
Sbjct 1	MADSNGTITVEELKKLLEQWNLVIGFLFLTWICLLQFAYANRNRFLYIIKLIFLWLLWPV				60
Query 61	TLACFVLAAYVRINWITGGIAIACLVGLMWLSYFIASFRLFARTRSMWSFNPETNILL				120
Sbjct 61	TLACFVLAAYVRINWITGGIAIACLVGLMWLSYFIASFRLFARTRSMWSFNPETNILL				120
Query 121	NVPLHGTLTRPLLESELVIGAVILRGHLRIAGHHLGRCDIKDLPKEITVATSRTLSTYYK				180
Sbjct 121	NVPLHGTLTRPLLESELVIGAVILRGHLRIAGHHLGRCDIKDLPKEITVATSRTLSTYYK				180
Query 181	LGASQRVAGDSGFAAYSRYRIGNYKLNTDHSSSSDNIALLVQ		222		
Sbjct 181	LGASQRVAGDSGFAAYSRYRIGNYKLNTDHSSSSDNIALLVQ		222		

membrane glycoprotein, partial [Severe acute respiratory syndrome coronavirus 2]

Sequence ID: [QJX59978.1](#) Length: 20 Number of Matches: 1

[See 4 more title\(s\)](#) [See all Identical Proteins\(IPG\)](#)

Range 1: 11 to 20 [GenPept](#) [Graphics](#)

[Next Match](#) [Previous Match](#)

Score	Expect	Identities	Positives	Gaps
37.1 bits(80)	0.074	10/10(100%)	10/10(100%)	0/10(0%)
Query 1	EELKKLLEQW	10		
Sbjct 11	EELKKLLEQW	20		

Expect Value: E-value

Identities/Percent Identity: a extensão em que duas sequências (nucleótidos ou aminoácidos) têm os mesmos resíduos nas mesmas posições num alinhamento

Positive: corresponde ao número de nucleótidos/ aminoácidos que são idênticos entre as duas sequências ou têm propriedades químicas semelhantes (*Conservative replacement/substitution*)

Gap: 1 ou mais nucleótidos/ aminoácidos foram deletados ou inseridos numa das sequências comparadas