

BIOINFORMÁTICA

Proteómica





Luís Melo

Introduction – central and new dogma



Escola de Engenharia
Universidade do Minho



<https://www.proteomicscenter.nl/background-information/>

Introduction

- Genomics: field of biology focusing on the structure, function, evolution, mapping, and editing of genomes (eg. Drug discovery, understand cellular actions);
- Transcriptomics: focuses on the study of the complete set of RNA transcripts that are produced by the genome, under specific circumstances (eg. determine the transcriptional structure of genes);
- Proteomics: seeks to correlate directly the involvement of specific proteins, protein complexes and their modification status in a given phenomenon (eg. identify proteins, modifications of proteins, interactions between proteins).

Definitions


- Proteomics is the large-scale study of proteins, particularly their structures and functions
- The **proteome** is the entire complement of proteins including the modifications made to a particular set of proteins, produced by an organism or system.
- proteome = protein + genome (M. Wilkins, 1994)



From the genome to the proteome




Escola de Engenharia
Universidade do Minho



Proteomics studies



Escola de Engenharia
Universidade do Minho



Genome *versus* Proteome



Escola de Engenharia
Universidade do Minho

Genome

- Essentially static over time
- Non location specific
- Human genome mapped in 20000-25000 genes
- PCR is available to amplify DNA



Proteome

- Dynamic over time
- Location specific
- Human proteome non-mapped (how many??)
- No equivalent PCR method for proteins





Genome -> Proteome



Escola de Engenharia
Universidade do Minho

- Large increase in protein diversity mainly due to:
 - Alternative splicing of pre-mRNA (introns and exons)
 - Post-translational modifications
 - Cell age and cell stage (healthy/disease)



Model of 1,58 yeast proteins & their 1,948 interactions.
Work by Hawoong Jeong & colleagues at U. Notre Dame


Amino acids



Escola de Engenharia
Universidade do Minho

- 20 naturally occurring amino acids

SMALL	 Glycine (Gly, G) MW: 75.07	 Alanine (Ala, A) MW: 89.09	NUCLEOPHILIC	 Serine (Ser, S) MW: 105.09, pK _a ~ 16	 Threonine (Thr, T) MW: 119.1, pK _a ~ 16	 Cysteine (Cys, C) MW: 121.2, pK _a = 8.18
	 Valine (Val, V) MW: 117.1	 Leucine (Leu, L) MW: 131.2		 Isoleucine (Ile, I) MW: 131.2	 Methionine (Met, M) MW: 149.2	 Proline (Pro, P) MW: 115.1
	 Phenylalanine (Phe, F) MW: 165.2	 Tyrosine (Tyr, Y) MW: 181.2, pK _a = 10.46		 Tryptophan (Trp, W) MW: 204.2	ACIDIC	 Aspartic Acid (Asp, D) MW: 133.1, pK _a = 3.9
	 Asparagine (Asn, N) MW: 132.1	 Glutamine (Gln, Q) MW: 146.1		 Histidine (His, H) MW: 155.2, pK _a = 6.04		 Lysine (Lys, K) MW: 146.2, pK _a = 10.79
AROMATIC				 Arginine (Arg, R) MW: 174.2, pK _a = 12.48		
HYDROPHILIC						
BASIC						



Protein backbone




Escola de Engenharia
Universidade do Minho

Individual amino acids



peptide bond

polypeptide




Methods



Escola de Engenharia
Universidade do Minho

- Proteomics research is typically divided into two categories:
 - Discovery
 - optimizes protein identification by spending more time and effort per sample
 - inventory proteins in a sample
 - detect differences in the abundance of proteins
 - between multiple samples
 - Targeted
 - optimizes the acquisition methods to achieve the highest sensitivity and throughput
 - pharmaceutical and diagnostic applications
 - Typically less than one hundred proteins




Protein separation



Escola de Engenharia
Universidade do Minho

- Proteome profiling/separation
 - SDS-PAGE (sodium dodecylsulphate polyacrylamide gel electrophoresis)
 - 2D SDS PAGE (two-dimensional sodium dodecylsulphate polyacrylamide gel electrophoresis)





https://www.researchgate.net/figure/SDS-PAGE-and-two-dimensional-gel-electrophoresis-2DE-stained-gel-with-Coomassie_fig1_341510200


SDS-PAGE



Escola de Engenharia
Universidade do Minho



<https://www.mdpi.com/1424-8220/7/3/371>




<https://blog.edvotek.com/2020/02/13/biotechnology-basics-sds-polyacrylamide-gel-electrophoresis/>

2D SDS-PAGE



Escola de Engenharia
Universidade do Minho

- Separation of proteins:
 - in one dimension by their pI's using an immobilized pH gradient (first dimension: isoelectric focusing)
 - then by their MW's in the second dimension



Isoelectric point (pI):

The pH value where the net charge of an amphoteric molecule is zero.


Immobilized pH gradient:

Polyacrilamide gels, which contain an in-built pH gradient, created by acrylamide derivatives, which carry acidic and basic buffering groups.

Isoelectric focusing




Escola de Engenharia
Universidade do Minho




2D results



Escola de Engenharia
Universidade do Minho



SDS Buffer



Urea Buffer

SDS-PAGE

■ Advantages

- Provides a hard-copy record of separation
- Allows quantification
- Separation of up to 9000 different proteins
- Highly reproducible
- Gives info on M_w and pI
- Inexpensive

■ Disadvantages

- Limited pI range
- Proteins >150 kDa are not seen in 2D gels
- Difficult to see membrane proteins ($>30\%$ of all proteins)
- Only detects high abundance proteins (top 30% typically)
- Time consuming

Mass Spectrometry


- In general a mass spectrometer consists of:
 - Ion Source
 - Mass Analyzer
 - Detector
- Mass spectrometers are used to quantify the mass-to-charge (m/z) ratios of substances
 - Molecular weight divided by the charge on this protein
- From this quantification, a mass is determined, proteins are identified, and further analysis is performed

Mass Spectrometry



Escola de Engenharia
Universidade do Minho

- MS is used to determine the elemental composition of a sample or molecule, and for elucidating the chemical structures of molecules, namely peptides and other chemical compounds.




Many applications...
One of them is proteomics

Mass Spectrometry



Escola de Engenharia
Universidade do Minho




https://upload.wikimedia.org/wikipedia/commons/1/1f/Mass_spectrometry_protocol.png

Bioinformatics



Escola de Engenharia
Universidade do Minho

Need for bioinformatics



Biology is changing

- High-throughput
- More data produced
- New types of data
- Emphasis on systems biology

Bioinformatics enables new applications

- Molecular medicine
- Agriculture
- Food
- Environmental samples

Bioinformatics need in proteomics



Escola de Engenharia
Universidade do Minho




On 21 July 1986, SWISS-PROT was created by A. Bairoch (contained approx 3900 protein sequences)

In 1979, the first software was developed for 2D image analysis



Estruturas de proteínas


- **Estrutura primária da proteína**
 - é a sequência de uma cadeia de aminoácidos
- **Estrutura secundária da proteína**
 - ocorre quando os aminoácidos da sequência se ligam através de ligações de hidrogénio
- **Estrutura terciária da proteína**
 - ocorre quando existem atrações estão entre as estruturas secundárias (e.g. α -hélices, β -folhas)
- **Estrutura quaternária de proteínas**
 - uma proteína necessita de várias subunidades de diferentes cadeias de aminoácidos



Estrutura secundária - PDB



Escola de Engenharia
Universidade do Minho



Ferramenta para prever estrutura secundária:

NetSurfP ver. 1.1 - Protein Surface Accessibility and Secondary Structure Predictions

<http://www.cbs.dtu.dk/services/NetSurfP-1.1/>

Estrutura terciária

- Base de dados PDB (Protein Data Bank)
 - Contém informações sobre estruturas de proteínas determinadas experimentalmente
 - Os dados presentes na PDB são curados e anotados de acordo com normas acordadas
 - É possível realizar pesquisas simples e avançadas, baseadas em anotações relativas a sequência, estrutura e função, e visualizar, fazer download e analisar moléculas

<http://www.rcsb.org/pdb/home/home.do>



Estrutura terciária



Escola de Engenharia
Universidade do Minho

RCSB PDB Deposit Search Visualize Analyze Download Learn More [MyPDB](#)

RCSB PDB 146266 Biological Macromolecular Structures Enabling Breakthroughs in Research and Education
PROTEIN DATA BANK

Search by PDB ID, author, macromolecule, sequence, or ligands [Go](#)
[Advanced Search](#) | [Browse by Annotations](#)

[PDB-101](#) [EMDataBank](#) [Molecular Structure Database](#) [Worldwide Protein Data Bank Foundation](#)

[Structure Summary](#) [3D View](#) [Annotations](#) [Sequence](#) [Sequence Similarity](#) [Structure Similarity](#) [Experiment](#)

[Display Files](#) [Download Files](#)

1U74
Electron Transfer Complex between cytochrome C and cytochrome C peroxidase
DOI: [10.2210/pdb1U74/pdb](https://doi.org/10.2210/pdb1U74/pdb)
Classification: [OXIDOREDUCTASE](#)
Organism(s): [Saccharomyces cerevisiae \(strain ATCC 204508 / S288c\)](#)
Expression System: [Escherichia coli BL21\(DE3\)](#)
Mutation(s): 1 [i](#)

Deposited: 2004-08-02 Released: 2004-09-28
Deposition Author(s): [Crane, B.R.](#), [Kang, S.A.](#)

Experimental Data Snapshot
Method: X-RAY DIFFRACTION
Resolution: 2.4 Å
R-Value Free: 0.287
R-Value Work: 0.260

wwPDB Validation [3D Report](#) [Full Report](#)

Metric	Percentile Ranks	Value
Rfree		0.283
Clashscore		10
Ramachandran outliers		1.5%
Sidechain outliers		12.9%
RSRZ outliers		7.8%

Worse Better
■ Percentile relative to all X-ray structures
□ Percentile relative to X-ray structures of similar resolution



Biological Assembly 1 [?](#)

[3D View: Structure](#) | [Electron Density](#) | [Ligand Interaction](#)

Standalone Viewers
[Protein Workshop](#) | [Ligand Explorer](#)

Escola de Engenharia
Universidade do Minho


Heterodímero



Há 2 tipos de estruturas quaternárias: homodímeros (proteínas com subunidades de estruturas semelhantes) e heterodímeros (proteínas com subunidades de estruturas diferentes).

Proteínas Transmembranares



- Uma **proteína transmembranar** é um tipo de proteína que envolve a totalidade da membrana biológica à qual está permanentemente ligada.
- Principais funções:
 - servir como canais transportadores de iões ou moléculas, como por exemplo as aquaporinas que transportam água através da membrana;
 - receção de sinais celulares



Também existem proteínas transmembranares que envolvem a totalidade da membrana biológica e tem diversas funções. Têm 2 tipos de domínios: as alfa hélices e os beta barris (mais presentes nas membranas externas e nas paredes das gram + e ainda em alguns organelos).

Domínios transmembranares em proteínas

- Dois tipos básicos de domínios transmembranares:
 - α -hélices
 - membrana interna das bactérias
 - membrana plasmática de eucariotas
 - por vezes nas membranas externas
 - β -barris
 - membranas exteriores de bactérias gram-negativas
 - parede celular de bactérias Gram-positivas
 - membranas exteriores das mitocôndrias e cloroplastos
- Ferramentas
 - Previsão de hélices transmembrana em proteínas
 - <http://www.cbs.dtu.dk/services/TMHMM>
 - http://www.ebi.ac.uk/Tools/services/web_phobius/toolform.ebi



Localização sub-celular


- Importante para a compreensão da função das proteínas
 - um passo crítico na anotação do genoma
- Melhorar a identificação do alvo
 - proteínas secretadas
 - proteínas localizadas na membrana são mais acessíveis às moléculas
- Ferramentas
 - Previsão de localização de proteínas
 - PSort - www.psort.org
 - TargetP - www.cbs.dtu.dk/services/TargetP/
 - Cell-PLoc 2.0 - www.csbio.sjtu.edu.cn/bioinf/Cell-PLoc-2
 - LOctree - <https://roslab.org/services/loctree3/>
 - MultiLoc - <http://abi.inf.uni-tuebingen.de/Services/MultiLoc>

Modificações pós-tradução



Escola de Engenharia
Universidade do Minho

- São modificações que ocorrem na proteína após a tradução da sequência de nucleótidos em aminoácidos
- Aumenta a diversidade funcional do proteoma
- Permite que o mesmo produto proteico da tradução possa adquirir diferentes funções
- Regulação de processos celulares
- Transporte através de membrana
- Essencial por vezes para a formação de estruturas secundárias e terciárias que irão tornar a proteína activa




Estruturas de proteínas



Escola de Engenharia
Universidade do Minho

- Vários tipos de modificações:

- Glicosilação
- Fosforilação
- Hidroxilação
- Acetilação
- Metilação
- Lipidação



- (existem mais de 150 tipos de modificações descritos)

Dependendo se as proteínas estão ou não fosforiladas, terão diferentes funções e formas. O mesmo acontece com a hidroxilação, acet

Glicosilação



Escola de Engenharia
Universidade do Minho

■ Ligação de moléculas de açúcares a proteínas


• Importante para:

- Localização sub celular (e.g. fixação à matriz extracelular)
- Interações célula-célula
- Interações proteína-ligando

• Ferramentas:

- Locais de glicosilação ligada a nitrogénio(N-glycosylation) em proteínas humanas


<http://www.cbs.dtu.dk/services/NetNGlyc/>



Fosforilação


- Mecanismo mais comum de regulação da função da proteína e transmissão de sinais na célula, ocorre com ligação de grupo de um fosfato às proteínas
- Estima-se que um terço das proteínas no proteoma humano sejam fosforiladas em alguma altura
- **Importante para:**
 - Ligação de proteínas
 - Ciclos celulares
 - Vias de sinalização
 - Regulação de enzimas
- **Ferramentas**
 - Locais genéricos de fosforilação em proteínas de eucariotas

<http://www.cbs.dtu.dk/services/NetPhos/>




Hidroxilação

- Um dos processos mais complexos de modificação pós tradução:
 - ligação de um grupo hidroxilo a uma proteína
- O principal resíduo a ser hidroxilado em proteínas é a prolina
- **Importante para:**
 - Hidroxilação da prolina (hidroxiprolina é um dos principais componentes da proteína colagénio)
 - Hidroxilação da lisina (hidroxilisina também é um componente do colagénio)




Acetilação

- Introdução de um grupo funcional de acetilo em proteínas
- **Importante para:**
 - Grupos acetilo podem ligar ou desligar proteínas (e genes)
 - Acetilação do terminal amino de uma proteína podem funcionar como sinal de degradação
- A regulação dos fatores de transcrição, proteínas efectoras, e proteínas do citoesqueleto é geralmente efetuada por mecanismos de acetilação e desacetilação pós-tradução



Metilação

- Um dos mais comuns processos de modificação pós tradução:
 - Adição ou transferência de grupos metilo
 - mediada por metiltransferases, metionina e S-adenosilmetionina
 - SAM
- **Importante para:**
 - aumenta a hidrofobicidade da proteína e pode neutralizar a carga negativa de aminoácidos, quando ligados a ácidos carboxílicos
 - regulação epigenética (metilação e desmetilação das histonas influencia a disponibilidade de ADN para a transcrição)
- Mecanismo tão frequente que foi sugerido que SAM é o substrato mais utilizado em reacções enzimáticas após o ATP



Modificações pós-tradução – UniProt



Escola de Engenharia
Universidade do Minho

PTM / Processing¹

Molecule processing

Feature key	Position(s)	Length	Description	Graphical view	Feature identifier	Actions
Signal peptide ⁱ	1 – 24	24				Add BLAST
Chain ⁱ	25 – 365	341	HLA class I histocompatibility antigen, A-31 alpha chain		PRO_0000018823	Add BLAST

Amino acid modifications


Feature key	Position(s)	Length	Description	Graphical view	Feature identifier	Actions
Glycosylation ⁱ	110 – 110	1	N-linked (GlcNAc...) By similarity			
Disulfide bond ⁱ	125 ↔ 188		PROSITE-ProRule annotation			
Disulfide bond ⁱ	227 ↔ 283		PROSITE-ProRule annotation			
Modified residue ⁱ	343 – 343	1	Phosphoserine Combined sources			
Modified residue ⁱ	344 – 344	1	Phosphotyrosine Combined sources			
Modified residue ⁱ	345 – 345	1	Phosphoserine Combined sources			
Modified residue ⁱ	349 – 349	1	Phosphoserine Combined sources			
Modified residue ⁱ	350 – 350	1	Phosphoserine By similarity			
Modified residue ⁱ	352 – 352	1	Phosphoserine Combined sources			
Modified residue ⁱ	356 – 356	1	Phosphoserine Combined sources			
Modified residue ⁱ	359 – 359	1	Phosphoserine Combined sources			

O Uniprot permite verificar as modificações pos tradução das proteínas.

Conclusion



Escola de Engenharia
Universidade do Minho



doi.org/10.1007/978-3-319-98758-3_3

Concluindo, o numero de sequencias esta a aumentar exponencialmente e a bioinformática é crucial para continuar este desenvolvimento.