

Bioinformatics
Module 3 – session 5

Machine Learning for omics data

Omics data sources and structure

Unsupervised and supervised learning applications over omics data

Fontes e estrutura dos dados ômicos
Aplicações de aprendizagem não supervisionada e supervisionada sobre dados ômicos

(Começar em larga escala)

Biological / omics data

Biology has become in recent years a science with a relevant contribution to the generation of large amounts of data

Biological data has grown due to technological developments in DNA sequencing and many other high-throughput techniques, that allow the measurement of large-scale data – called omics data

Data analysis for biological domains is a growing need in research or industrial tasks, requiring knowledge of the interconnections of different entities and systems

Biology is currently a science largely based on data and information


A biologia tornou-se nos últimos anos uma ciência com uma contribuição relevante para a geração de grandes quantidades de dados

Os dados biológicos têm crescido devido aos desenvolvimentos tecnológicos na sequenciação de ADN e muitas outras técnicas de elevado rendimento, que permitem a medição de dados em grande escala - os chamados dados ómicos

A análise de dados em domínios biológicos é uma necessidade crescente na investigação ou tarefas industriais, que requerem conhecimento de interconexões de diferentes identidades e sistemas. A biologia atualmente é baseada em dados e informação em larga escala.

(Transcriptômica - genes expressos numa determinada situação
Proteômicas - proteínas de uma certa célula)

Biological systems and omics data



(a ideia é tentar modelar modelos de sistemas biológicos para perceber perturbações, etc. que levem a alterações nos fenótipos por ex.)

Omics data

Genomics

Data sequencing – complete genomes, exomes, analysis of variants and mutations, etc..

Transcriptomics

Measurement of gene expression(mRNA)

RNA sequencing, DNA microarrays

(atualmente é feita pela sequenciação de mRNA ou do DNA)

Epigenomics

Measuring DNA marks, such as DNA methylation (e.g. from sequencing)

Proteomics

Measurement of the amount of proteins

Mass spectrometry(MS), protein microarrays, ...

(proteomica e metabolomica ambas medem quantidade, por isso são relativamente semelhante)

Metabolomics

Measurement of the amount of small compounds involved in metabolism

Chromatography + MS, Nuclear Magnetic Resonance, etc

Interactomics

Protein-DNA Interactions, protein-protein, ...

(para perceber quais as proteínas ou outras moléculas que integram, para perceber melhor a sua função, como é regulada, como regula outras coisas, etc.)

Genómica: Sequenciação de dados - genomas completos, exomas, análise de variantes e mutações, etc.

Transcriptómica: Medição da expressão genética (mRNA); Sequenciação de ARN, microarrays de ADN


Epigenómica: Medição das marcas de ADN, como a metilação do ADN (por exemplo, a partir de sequenciação);

Proteómica: Medição da quantidade de proteínas; Espectrometria de massa (MS), microarrays de proteínas, ...

Metabolómica: Medição da quantidade de pequenos compostos envolvidos no metabolismo Cromatografia + MS, Ressonância Magnética Nuclear, etc.

Interactómica: Interações proteína-DNA, proteína-proteína, ...

The Cancer Genome Atlas Multi-Dimensional data



Omics data sources/ databases

Gene expression data

(repositório mais usado e mais importante para esta UC)

- general-purpose repositories: Gene Expression Omnibus (GEO), Array Express, Expression Atlas

(repositório bom porque as pessoas vão colocando dados das suas experiências)

- human data (+ cancer): GTEX, GDC (ex-TCGA)

(expressão genética em tecidos normais)

Metabolomics

- Metabolights, Metabolomics Workbench, HMDB

Proteomics/ interactomics

- PRIDE, HGPD, ProteomicsDB, Human Protein Atlas
- Protein interactions: STRING, BioGRID, IntAct, MINT, HRPD

Dados de expressão genética: repositórios de uso geral- Gene Expression Omnibus (GEO), Array Express, gene expression data dados humanos (+ cancro): GTEX, GDC (ex-TCGA)

Metabolómica: Metabolights, Metabolomics Workbench, HMDB

Proteómica/interactiva: PRIDE, HGPD, ProteomicsDB, Atlas de proteínas humanas; Interações proteicas: STRING, BioGRID, IntAct, MINT, HRPD

(a expressssao genetica pode ser medida por sequenciação de RNA (perceber quais sao as proteínas e qual a sua quantidade) ou por DNA microarrays)

(+ RNA indica mais atividade (ou seja, pelo dogma central (slide 3) é verdadeira esta frase mas não 100% porque tudo depende...mRNA (transcriptômica) vai influenciar a proteômica (proteínas))

Mas é mais facil medir assim e por isso usa se bastante)

Gene expression data

Techniques such as *DNA microarrays and RNA sequencing* measure the **expression level of all genes** in a cell, in various conditions/instants of time

Expression level of a given gene is estimated by measuring the amount of respective mRNA.

The given **assumptions** are used (not always true)

A gene is active if it is being transcribed

More mRNA indicates more gene activity

Técnicas como os microarrays de ADN e a sequenciação de ARN medem o nível de expressão de todos os genes de uma célula, em várias condições/instantes de tempo O nível de expressão de um determinado gene é estimado através da medição da quantidade do respetivo mRNA.

São utilizados os seguintes pressupostos (nem sempre verdadeiros):

-Um gene está ativo se estiver a ser transcrito

-Mais ARNm indica maior atividade do gene

RNA Sequencing

Latest techniques of ^(NGS) **next generation sequencing** allow to sequence cDNA and thus have measurements of the associated mRNA

These provide more accurate measurements of RNA by reading extracts of 30~400 bps; less background noise


They allow the measurement of transcriptomes of unsequenced organisms

They allow to detect differences in a larger scale (greater dynamic range) up to values of 8000 times

Technologies: *Illumina, Roche 454, ABS*

As técnicas mais recentes de sequenciação de nova geração permitem sequenciar o cDNA e, assim, obter medições do mRNA associado. Estas técnicas permitem medições mais exactas do ARN através da leitura de extractos de 30~400 bps; menos ruído de fundo. Permitem a medição de transcriptomas de organismos não sequenciados. Permitem detetar diferenças em maior escala (maior gama dinâmica) até valores de 8000 vezes.
Tecnologias: Illumina, Roche 454, ABS

RNA-Sequencing Experiment



Adapted from: Wang Z, Gerstein M, Snyder M. RNA-Seq: a revolutionary tool for transcriptomics. Nat Rev Genet. 2009

Data preparation

Data from the equipment is typically large and contains lots of information that needs to be processed before analyzing the data

Much of the initial treatment is performed by specific software for each equipment, being dependent on experience and equipment

RNA seq data have some distinct processing steps as they are absolute counts (which have to be normalized by the total number)

We will not address the specifics of data preparation for any case, assuming we can reach a standard representation (provided next)

Os dados do equipamento são normalmente grandes e contêm muitas informação que precisa de ser processada antes de analisar os dados
Grande parte do tratamento inicial é efectuado por software específico para cada equipamento, estando dependente da experiência e do equipamento
Os dados de RNA seq têm alguns passos distintos de processamento, uma vez que são absolutas (que têm de ser normalizadas pelo número total)
Não abordaremos as especificidades da preparação dos dados para nenhum caso, assumindo que podemos chegar a uma representação padrão (fornecida de seguida)

Representation of omics data

Omics data typically follow a **matrix structure** : typically numerical variables – measurement of biological entities (e.g. genes, proteins, metabolites) – lines - in different samples – columns.

Typically large matrices, especially with respect to the number of rows;

It is also common to consider the samples in the rows (transposing the matrix) in some types of analyses

(Refletem qual é o grau de expressão do gene)

(Assume-se que se tem datasets com estas características)

(Normalmente são dados numéricos mas para cada amostra há informação com metadados)

	Sample 1	Sample 2	Sample 3	...
Gene 1	4.5	12.1	9.7	...
Gene 2	12.4	7.8	7.3	..
Gene 3	9.4	6.5	8.9	...
Gene 4	13.1	15.1	12.7	...
Gene 5	8.5	11.3	14.1	...
...	...	...	...	...

Os dados ómicos seguem normalmente uma estrutura matricial: variáveis tipicamente numéricas - medição de entidades biológicas (por exemplo, genes, proteínas, metabolitos) - linhas - em diferentes amostras - colunas.

Normalmente, são matrizes grandes, especialmente no que respeita ao número de linhas;

Também é comum considerar as amostras nas linhas (transpondo a matriz) em alguns tipos de análises

Metadata representation

In the analysis of omics data, there are complementary variables on the samples (e.g. clinical/phenotypic data), which may be important from the point of view of analysis

We usually call these **metadata**, and can be represented in another matrix, following the previous structure

In some cases, this matrix (or part) is joined with the data matrix for the purposes of some types of analysis

Metadados:

(estes metadados têm informações sobre o processo do paciente)

	Blood test	Mutations	Smoker	Cancer subtype
Sample 1	234.1	Negative	Yes	A
Sample 2	117.2	A	No	B
Sample 3	90.7	B	No	A
Sample 4	85.9	B	No	B
...	...	...	...	...

-Na análise dos dados ómicos, existem variáveis complementares nas amostras (por exemplo, dados clínicos/fenotípicos), que podem ser importantes do ponto de vista da análise

-Chamamos-lhes habitualmente metadados, que podem ser representados noutra matriz, seguindo a estrutura anterior

-Nalguns casos, esta matriz (ou parte dela) é unida à matriz de dados para efeitos de alguns tipos de análise

(basta ter uma ideia!

em dados experimentais normalmente há missing values)

Data pre-processing

Even when we already have the data in the previous matrix format, there is a need for some additional pre-processing tasks for various data analysis tasks.

Pre-processing steps at this level include missing value handling, normalization, flat pattern filters, logarithmic transformations, etc.

These steps allow the data to be of more tractable dimensions and to be in appropriate value ranges for further analysis


Mesmo quando já dispomos dos dados no formato matricial anterior, é necessário efetuar algumas tarefas adicionais de pré-processamento para tarefas de análise de dados.

As etapas de pré-processamento a este nível incluem o tratamento de valores em falta, normalização, filtros de padrão plano, transformações logarítmicas, etc.

Estas etapas permitem que os dados tenham dimensões mais tratáveis e estejam em intervalos de valores apropriados para análise posterior

Data pre-processing

(a transformação logarítmica é necessária porque ha casos em que ha genes com expressao muito alta e genes com expressao muito baixa e estas escalas sao muito diferentes de gene para gene, por isso, aplica se a transformação logarítmica atenua esta diferença)




- Log scale transformation is essential: reduces the range, stabilizes the variance and brings symmetry.
- Filtering of genes with minimal expression or minimal variability across samples.
- Selecting genes from a specific biotype, like protein-coding and lincRNAs.

- A transformação da escala logarítmica é essencial: reduz o intervalo, estabiliza a variância e traz simetria.
- Filtragem de genes com expressão mínima ou variabilidade mínima entre amostras.
- Seleção de genes de um biótipo específico, como os codificadores de proteínas e os lincRNAs.

Logarithmic transformation

Ratio = RNA level experience / RNA level control



Log 2:

(...)

Ratio $\frac{1}{2}$ – log = -1


Ratio 1 – log = 0

Ratio 2 – log = 1

Ratio 4 – log = 2

(...)

$$|\log_2(0.01)| == \log_2(100)$$



(a transformação logaritmica tambem pode ser usada para experiencias com controlo. Se uma for maior que a outra, se se fizer o racio, se a experiencia for maior que o controlo, vai dar de 1 a infinito.

se a experiencia for menor que o controlo, está entre 0 e 1.

Para equalizar estas 2 avaliações, usam-se os logaritmos.)

(remover genes que variam pouco (mede-se a variação dos genes (com desvio padrão, erro padrão, etc.) e filtra-se os que se quer))

Flat pattern filters

(filtros de Flat Pattern) ----> é ser capaz de dizer que os genes não variam muito entre si, podendo remover-se ou usar-se

Genes with very constant values usually do not bring relevant information

HOW TO DETECT?

Standard deviation / mean absolute deviation/ IQR
Value of minimum and maximum peaks (e.g. max/min)

SOLUTION

Remove these genes from the analysis
Remove only those that have average values close to 0

Os genes com valores muito constantes geralmente não trazem informações relevantes

COMO DETECTAR?

- Desvio padrão / desvio médio absoluto / IQR
- Valor dos picos mínimo e máximo (por exemplo, max/min)

SOLUÇÃO

- Retirar estes genes da análise
- Remover apenas os que têm valores médios próximos de 0

Standardization – between samples

Typically, values are re-scaled to stay within normalized limits (normal distribution with mean 0 and variance 1)

How:

Subtract the value of each gene by the mean (or median) of the expression values

Divide by the sample standard deviation (or mean absolute deviation)

Sometimes only the first one is done

Normalmente, os valores são redimensionados para se manterem dentro dos limites normalizados (distribuição normal com média 0 e variância 1)

Como:

- Subtrair o valor de cada gene pela média (ou mediana) dos valores de expressão valores
- Dividir pelo desvio padrão da amostra (ou desvio médio absoluto)
- Por vezes, só é efectuada a primeira operação

Basic issues in gene expression data analysis

Model reconstruction

(é necessário ter muitos dados para fazer estes modelos)

Build genetic models/networks

Which genes are differentially expressed between set(s) of samples

Statistical inference

(Ex: conjunto de amostras com cancro vs amostras de pacientes normais)

How to predict sample classes based on gene expression


Classification

(Caso supervisionado - como prever classes das amostras com base na expressão genética)

What are the best groupings of genes or samples

Clustering

(Caso não supervisionado)



(o objetivo é perceber como identificar um determinado fenótipo)

Differential expression

In terms of biological research, it is very importante to **identify the set of genes that have different levels of expression** comparing two (or more) experimental conditions (e.g. normal vs cancer cell, wild type vs mutant).


The identification of genes that are differentially expressed is based on **statistical hypothesis testing**, based on the assumption that gene expression values are "generated" following a Normal distribution.

Em termos de investigação biológica, é muito importante identificar o conjunto de genes que têm diferentes níveis de expressão comparando duas (ou mais) condições experimentais (por exemplo, célula normal vs. célula cancerosa, tipo selvagem vs. mutante).

A identificação dos genes diferencialmente expressos baseia-se em testes estatísticos de hipóteses, baseados no pressuposto de que os valores de expressão dos genes são "gerados" segundo uma distribuição normal.

(os genes que se querem é os genes em que os padrões de expressão dos genes é diferente (curvas diferentes, separadas). Como saber? Testes específicos, com paramétricas, etc.)

Differential expression



Null hypothesis: Are the means of the transcription levels of the two situations identical?

Hipótese nula: As médias dos níveis de transcrição das duas situações são idênticas? duas situações são idênticas?

DE: statistical tests

T-test (se os dados se distribuírem normalmente)

- paired if the samples are paired se as amostras são emparelhadas
- Unpaired if they are not related

We calculate the t-statistic and the correspondent p-value;

- Lower p-values mean greater confidence that means are different

(Testes não paramétricos servem para vários tipos de dados)

Non-parametric tests may be used (e.g. Mann-Whitney) if the distributions of the data are not approximately normal

T-teste

- emparelhadas se as amostras são emparelhadas se as amostras são emparelhadas
- Não emparelhadas se não estiverem relacionadas

Calculamos a estatística t e o valor p correspondente;

- Valores de p mais baixos significam maior confiança de que as médias são diferentes

Podem ser utilizados testes não paramétricos (por exemplo, Mann-Whitney) se as distribuições dos dados não forem aproximadamente normais

DE: other statistical analyses

One way **ANOVA** (analysis of variance)

- When we have 3 or + groups of conditions (samples)
- Non-parametric versions can be used

(3 ou + grupos - ANOVA)

Multifactor ANOVA

- when we have 2 or + factors (variables)

General linear models – linear regression

- may incorporate analysis of the influence of continuous variables

(fazer regressão linear com várias variáveis e ver como a expressão varia com os genes mais genéricos podem estudar-se diferentes tipos de modelos de regressão para entender quais os genes que variam de acordo com os fatores que se estão a estudar)

ANOVA (análise de variância)

- Quando temos 3 ou + grupos de condições (amostras)
- Podem ser utilizadas versões não paramétricas

ANOVA multifatorial

- quando temos 2 ou + factores (variáveis)

Modelos lineares gerais - regressão linear

- podem incorporar a análise da influência de variáveis contínuas

(Pode usar-se unsupervised learning como PCA, TSNE, e Clustering (porque pode querer-se agrupar amostras por exemplo ou então genes e saber quais é que estão relacionados))

Unsupervised learning for omics data

- When applied to omics data, unsupervised learning can be used to **explore** the data matrices, seeking patterns of different types, **without using external additional information**, using methods for clustering, dimensionality reduction
- Available **metadata** is not used to run the algorithms, but may be highly relevant in the **visualization and interpretation** of the results

- Quando aplicada a dados ómicos, a aprendizagem não supervisionada pode ser utilizada para explorar as matrizes de dados, procurando padrões de diferentes tipos, sem recorrer a informações adicionais externas, utilizando métodos de agrupamento, redução da dimensionalidade

- Os metadados disponíveis não são utilizados para executar os algoritmos, mas podem ser muito relevantes para a visualização e interpretação dos resultados

Dimensionality reduction for omics data

- Methods such as **PCA** may be used to analyse the main trends in the data variability, checking data redundancy and collinearity
- PCA, but also other methods such as **MDS** or **tSNE** may be used to visualize highly multidimensional omics data using few (latent) variables
- These plots may be coloured using different metadata variables, showing if trends in data support natural groups in data from these variables

- Métodos como a ACP podem ser utilizados para analisar as principais tendências na variabilidade dos dados, verificando a redundância e a colinearidade dos dados

- A PCA, mas também outros métodos como o MDS ou o tSNE, podem ser utilizados para visualizar dados ômicos altamente multidimensionais utilizando poucas variáveis (latentes) variáveis (latentes)

- Estes gráficos podem ser coloridos utilizando diferentes variáveis de metadados, mostrando se as tendências nos dados suportam grupos naturais nos dados destas variáveis

(redução de dimensionalidade pode ser usada para novas features e para feature selection)

Dimensionality Reduction

- DR is the process of reducing the number of input features under consideration and focus on a set of principal features.
 - **Feature selection**: apply statistical tests to infer the importance of the features and retain a subset. Implies information loss and less stability.
 - **Feature extraction**: create new independent features as combination of the original features. Linear and non-linear methodologies.
- Useful for data visualization. Focusing on 2 or 3 most important dimensions/components may allow to visually detect patterns, such as clusters.

DR é o processo de reduzir o número de características de entrada em de entrada em consideração e concentrar-se num conjunto de características principais.

- Seleção de características: aplicar testes estatísticos para inferir a importância das características e reter um subconjunto. Implica perda de informação e menor estabilidade.
- Extração de características: criar novas características independentes como combinação das características originais. Metodologias lineares e não lineares.

Útil para a visualização de dados. A concentração em 2 ou 3 dimensões/componentes mais importantes pode permitir detetar visualmente padrões, tais como agrupamentos.

Dimensionality Reduction

- In an n-dimensional dataset:
 - the training instances are not uniformly distributed across all dimensions.
 - Some features are always constant; others are highly correlated.
 - All training instances will actually lie a much more lower-dimensional space (of the original space).




Figure 8-2. A 3D dataset lying close to a 2D subspace

- Figure from Aurélien Géron, Hands-on ML with Scikit-Learn & TensorFlow, O'Reilly.

Num conjunto de dados n-dimensional:

- as instâncias de treino não estão uniformemente distribuídas por todas as dimensões.
- Algumas características são sempre constantes; outras estão altamente correlacionadas.
- Todas as instâncias de treino situar-se-ão, de facto, num espaço de dimensão muito mais baixa (do espaço original).

Dimensionality Reduction

- **Matrix factorization:** decompose a matrix into a product of matrices, e.g. PCA, NMF, MDS.
- **Neighbour graph:** build a graph representing distances between objects embedding it in a lower dimensional space: t-SNE, Isomap, UMAP.

- Factorização de matrizes: decompor uma matriz num produto de matrizes, por exemplo, PCA, NMF, MDS.

- Gráfico de vizinhança: construir um gráfico que represente as distâncias entre objetos, incorporando-o num espaço de dimensão inferior: t-SNE, Isomap, UMAP.

ALL dataset



ALL dataset

Acute lymphoblastic leukemia (ALL): most common leukemia in children.
ALL: information collected from 128 patients with leukemia (95 B lymphocyte cells and 33 T lymphocyte cells); 12625 genes measured by DNA microarrays.
Phenotype data of patients (metadata): age, sex, analytical data, molecular biology data, etc


- This classical gene expression dataset will be used to show some examples of the application of ML methods along this session

Leucemia linfoblástica aguda (LLA): leucemia mais comum em crianças. ALL: informações recolhidas de 128 pacientes com leucemia (95 linfócitos B e 33 linfócitos T); 12625 genes medidos por microarrays de ADN. Dados fenotípicos dos doentes (metadados): idade, sexo, dados analíticos, dados de biologia molecular, etc

Este conjunto de dados clássicos de expressão génica será utilizado para mostrar alguns exemplos de aplicação de métodos de ML ao longo desta sessão



Example: PCA for gene expression data



Dataset: ALL (leukemia)
Gene expression data

(Dataset com dados de leucemia)

Dá para ver que cerca de 30% são logo explicadas por 2 diferentes variáveis (2 iniciais)

Example: PCA for gene expression data



Dataset: ALL (leukemia)

Gene expression data

Metadata: B/ T cells, only used to colour the points representing the samples

Metadados: Células B/T, utilizadas apenas para colorir os pontos que representam as amostras

(Verifica-se que os cancros do tipo B e do tipo T se separam um pouco)

Example: PCA for gene expression data



Dataset: ALL (leukemia)

Gene expression data

Metadata: MDR (multi-drug resistance) status of the samples, only used to colour the points representing the samples

Metadados: Estado de MDR (resistência a múltiplos fármacos (resistência a múltiplos fármacos) das amostras, utilizado apenas para colorir os pontos que representam as amostras


Clustering for gene expression

- Clustering methods have been widely applied for gene expression and many other types of omics data
- The most common application is to use clustering algorithms to **group samples** based on their expressions levels, and in many cases seek to compare these groups to known metadata or to discover new putative classes
- An alternative is to **group genes** by their expression levels, thus highlighting co-regulated genes

- Os métodos de agrupamento têm sido amplamente aplicados à expressão genética e muitos outros tipos de dados ômicos
- A aplicação mais comum é a utilização de algoritmos de agrupamento para agrupar amostras com base nos seus níveis de expressão e, em muitos casos, procurar comparar estes grupos com metadados conhecidos ou descobrir novas classes putativas
- Uma alternativa consiste em agrupar os genes pelos seus níveis de expressão, destacando assim destacar genes co-regulados



Example: HC for gene expression data



Dataset: ALL (leukemia)

Gene expression data

Clustering samples

Colours of leafs represent the metadata variable MDR

Conjunto de dados: ALL (leucemia)

Dados de expressão de genes

Agrupamento de amostras

As cores das folhas representam a variável de metadados MDR

(clustering hierarquico aplicado sobre dados de expressão de leucemia. Está-se a fazer clustering de samples, para um teste de mutação.

Os que têm mutação são os verdes e os que não têm são vermelhos.


Dá para ver se o clustering dos meus dados é ou não semelhante aos dados do clustering.)

(Para ter um determinado fenótipo, muitas vezes é preciso ter genes a trabalhar em conjunto)

Clustering genes by their expression

Motivation: **Co-regulated genes should show behavior (expression levels) “similar”**


“Guilt by association”: if an unknown gene i is similar in expression to a known gene j , it is very likely to be involved in the same metabolic pathway



Motivação: Os genes co-regulados devem apresentar um comportamento (níveis de expressão) "semelhantes"

"Culpa por associação": se um gene desconhecido i é semelhante em expressão a um gene conhecido j , é muito provável que esteja envolvido na mesma via metabólica

Example: HC for gene expression data



Dataset: ALL (leukemia)
Gene expression data
Clustering genes

Conjunto de dados: ALL (leucemia)
Dados de expressão de genes
Agrupamento de genes

(heatmaps organizam os dados pelo clustering hierarquico e vê-se pelas cores que faz sentido a diferença. Quanto mais escuro, maior a expressão do gene)

Heatmaps

Way to represent matrix data where colours of each cell represent scale of values

Typically, heatmaps include hierarchical clustering trees created at the level of the rows and columns




Example with the **ALL dataset**

Shows expression levels of 30 genes, differentially expressed for the MDR metadata variable

Forma de representar dados matriciais em que as cores de cada célula representam a escala de valores

Normalmente, os mapas de calor incluem árvores de agrupamento hierárquico criadas ao nível das linhas e colunas




Exemplo com o conjunto de dados ALL
Mostra os níveis de expressão de 30 genes, diferencialmente expressos para a variável de metadados MDR

Example: clustering of gene expression data



Example:
leukemia



(Feature selection - quando se tem muitas features, muitos genes, como se resolve? O feature selection dá para remover (cuidadosamente, de modo a perder apenas informação pouco relevante) de uma forma lógica)

Feature selection

One of the biggest problems of the previous strategy: **Too many input features** (typically thousands)

Very complicated task of the algorithms to generate the models: greater complexity, more noise

Solution: Use only a subset of the attributes

Problem: How to select them ?

In the case of gene expression, problem is selecting subsets of genes that are "good bio-markers"!

Um dos maiores problemas da estratégia anterior: Demasiadas características de entrada (tipicamente milhares)

Tarefa muito complicada dos algoritmos para gerar os modelos: maior complexidade, mais ruído

Solução: Utilizar apenas um subconjunto de atributos

Problema: como seleccioná-los?

No caso da expressão genética, o problema é seleccionar subconjuntos de genes que são "bons bio-marcadores"!

(A expressão diferencial é poderosa. Se se quiser expressar numa unidade variável qualquer, os que tiverem grandes diferenças são melhores candidatos (melhores features) do que os que são semelhantes)
(Os métodos de expressão diferencial são exatamente os mesmos que os filtros do pptx anterior.
Os flat patterns (Semelhantes aos filtros de variabilidade) também podem ser usados como feature selections)

Feature selection

When selecting the genes/metabolites/... used in classification (*filters*):

- Choose the **differentially expressed** ones between the categories
- Those that allow a clear division of individuals into groups
- Remove those that behave similarly (e.g. *flat patterns*)
- Independent of classification models

Ao seleccionar os genes/metabolitos/... utilizados na classificação (filters):

- Seleccionar os genes diferencialmente expressos entre as categorias
- Os que permitem uma divisão clara dos indivíduos em grupos
- Remover os que se comportam de forma semelhante (por exemplo, padrões planos)
- Independente dos modelos de classificação

(Qualquer coisa que seja uma variável binária (Ex: género biológico de expressão), é uma classificação binária. Os inputs são os genes e samples e o output são os metadados (no caso do supervisionado).)

Classification of samples based on omics data

Typical problem of **Classification**:

- Input features: expression/concentration/... for the various genes/compounds/...
- Examples: samples
- Output feature: class of each sample (e.g. type of cancer, healthy/sick, treatment)

Objective: create models that allow to determine the value of the class for each sample given the values of the omics data in that case.

Problema típico de classificação:

- Características de entrada: expressão/concentração/... para os vários genes/compostos/...
- Exemplos: amostras
- Característica de saída: classe de cada amostra (por exemplo, tipo de cancro, saudável/doente, tratamento)

Objetivo: criar modelos que permitam determinar o valor da classe para cada amostra, dados os valores dos dados ómicos nesse caso.

(primeiro treina-se o modelo, com o conhecimento dos dados dos modelos e depois usa-se o modelo com dados desconhecidos.)

Classification of samples based on omics data

Step 1: **train**

- Given some samples for which the class is known – **build a model** that generalizes the data (function that takes as arguments the values of the input attributes - expression of each gene, concentration of each metabolite, ... - and gives as a result the class of the sample).

Step 2: using the model (**prediction**)

- For a new sample for which the class is not known, use the previous model to determine it, given the values of the omics data (e.g. gene expression)


Passo 1: treinar

- Dadas algumas amostras para as quais a classe é conhecida - construir um modelo que generaliza os dados (função que recebe como argumentos os valores dos atributos de atributos - expressão de cada gene, concentração de cada metabolito, ... - e dá como resultado a classe da amostra).

Etapa 2: utilização do modelo (previsão)

- Para uma nova amostra para a qual a classe não é conhecida, utilizar o modelo anterior para determiná-la, tendo em conta os valores dos dados ómicos (por exemplo, expressão genética)





ML Workflow



Libbrecht and Noble, Machine learning applications in genetics and genomics,
Nat Rev Genetics, 2015


(Exemplo de um artigo em que se prevê o TSS e o not TSS)

ML Workflow



(esta árvore está a tentar determinar a classe em função do modelo)

Example: classification of ALL data




Example of a **tree** model trained to predict the mutation status (metadata variable `mol.biol`) of the ALL dataset from gene expression data

In this model, only two genes (features) are used in the prediction and the problem was simplified to consider only two classes: BCR/ABL and NEG

Exemplo de um modelo de árvore treinado para prever o estado da mutação (variável de metadados variável `mol.biol`) do conjunto de dados ALL a partir de dados de expressão genética

Neste modelo, apenas dois genes (características) são utilizados na previsão e o problema e o problema foi simplificado para considerar apenas duas classes: BCR/ABL e NEG

Challenge: Integrate multiple types of data



- Molecular subtypes of gastric cancer

Adapted from: Cancer Genome Atlas Research Network. Comprehensive molecular characterization of gastric adenocarcinoma. Nature. 2014

Conclusions

Next-Generation Sequencing Pushes the limits of Bioinformatics.

Unsupervised Learning is an essential to explore the patterns in the data.

Integrative and systems-level view of cancer; complement to hypothesis driven approaches.

ML enables unbiased discovery from experimental data.

Keeps improving when more data is available.

Human-level performance in several tasks: effectively learn from very large, complex and even heterogeneous datasets.

Used under human guidance can reduce subjective evaluation and improve precise prognostication.

A sequencição de nova geração ultrapassa os limites da bioinformática.

A aprendizagem não supervisionada é essencial para explorar os padrões nos dados.

Visão integrativa e sistémica do cancro; complemento das abordagens baseadas em hipóteses.

O ML permite uma descoberta imparcial a partir de dados experimentais.

Continua a melhorar quando estão disponíveis mais dados.

Desempenho ao nível humano em várias tarefas: aprender efetivamente a partir de conjuntos de dados muito grandes, complexos e até heterogéneos.

Utilizado sob orientação humana, pode reduzir a avaliação subjectiva e melhorar o prognósticos precisos